

Guide méthodologique de la calculatrice *Impact'IA*



License :

Ce document est mis à disposition sous licence **Creative Commons CC-BY-NC-SA**

Vous êtes libre de :

- Partager : copier, distribuer et communiquer le document ;
- Adapter : modifier, transformer et enrichir son contenu ;
- Utiliser le document à toute fin, y compris professionnelle.
- Sous réserve de :
 - Créditer les auteurs originels ;
 - Indiquer les modifications réalisées ;
 - Fournir un lien vers la licence.

Contributeurs :

Prénom NOM	Organisation	Contact
Xavier VERNE	SNCF	xavier.verne@scnf.fr
Thibaud AUZIERE	SNCF	t.auziere@scnf.fr
Tatiana FOUQUET	Wavestone	tatiana.fouquet@wavestone.com
Benoit DURAND	Wavestone	benoit.durand@wavestone.com
Feriel SRAIEB	Wavestone	feriel.sraieb@wavestone.com
Rosendo MANAS FAURA	Resilio	rosendo.manasfaura@resilio-solutions.com
You LI	Resilio	you.li@resilio-solutions.com

Historique des versions :

Version	Date
1.0	07/2026

Sommaire



Contexte et
principes clés



Indicateurs
environnementaux



Périmètre
fonctionnel



Synthèse de la
méthodologie



Modélisation
détaillée

1

Contexte et principes clés de la calculatrice *Impact'IA*

L'essor massif de l'IA générative dégrade l'empreinte du numérique à l'échelle mondiale, sur toutes les dimensions environnementales



ÉLECTRICITÉ

Pour alimenter les datacenters



CLIMAT

Pour fabriquer les composants informatiques
Pour générer l'électricité



EAU

Pour refroidir les datacenters
Pour fabriquer les puces
Pour générer l'électricité



RESSOURCES ABIOTIQUES

Pour fabriquer les composants informatiques

En particulier, l'IA générative devient un facteur de premier ordre de la croissance de l'empreinte environnementale des datacenters.


La puissance d'un datacenter IA nécessite désormais l'équivalent d'un réacteur nucléaire pour son alimentation (1GW).

2


Indicateurs environnementaux

Qu'est-ce que la méthodologie d'Analyse du Cycle de Vie ?

L'Analyse de Cycle de Vie (ACV) est une méthodologie utilisée pour **évaluer les impacts environnementaux de produits ou services**. À l'échelle européenne, l'ACV est employée pour établir les **Product Environmental Footprint (PEF)** qui servent de **base à la mesure de l'empreinte environnementale** généralisée. Les **caractéristiques d'une Analyse du Cycle de Vie** sont les suivantes :



L'Analyse du Cycle de Vie (ACV) s'appuie sur 16 indicateurs environnementaux, qui permettent de mesurer l'impact de chaque étape de cycle de vie



16 indicateurs classés en 4 catégories d'impacts :



CLIMAT :

1. Potentiel de réchauffement climatique



BIODIVERSITÉ :

2. Acidification
3. Eutrophisation marine
4. Eutrophisation eau douce
5. Eutrophisation terrestre
6. Ecotoxicité eau douce
7. Utilisation des sols



SANTÉ ENVIRONNEMENTALE :

8. Appauvrissement de la couche d'ozone
9. Rayonnement ionisant
10. Formation photochimique d'ozone
11. Particules fines
12. Toxicité humaine cancérigène
13. Toxicité humaine non cancérigène



RESSOURCES :

14. Utilisation d'eau
15. Utilisation des ressources fossiles
16. Utilisation des ressources minérales/métaux

Pourquoi mener une Analyse du Cycle de Vie ?

- Identifier où se trouvent les plus gros impacts environnementaux
- Comparer plusieurs scénarios ou produits
- Concevoir des produits plus durables
- Répondre aux normes (ISO 14040/14044) et aux attentes RSE

Les indicateurs environnementaux choisis sont l'électricité (kWh), le potentiel de réchauffement climatique (CO2e) et l'utilisation d'eau (m3 eq) pour les raisons suivantes :



L'indicateur « Electricité » est également indispensable à modéliser :

- ✓ **Impact environnemental très structurant** (pour le numérique en général, et plus encore pour l'IA générative)
- ✓ **Proxy de premier ordre pour estimer le potentiel de réchauffement climatique**
- ✓ **Indicateur très compréhensible** par les futurs utilisateurs de la calculatrice

Remarque méthodologique : l'électricité ne correspond pas à un des 16 indicateurs environnementaux d'une ACV



L'indicateur « Potentiel de réchauffement climatique » est indispensable :

- ✓ **Conformité réglementaire** : obligation de reporting sur les émissions de gaz à effet de serre (BEGES), matérialité CSRD
- ✓ **Maturité** (relative) de la modélisation des émissions GES par rapport autres indicateurs environnementaux

Remarque méthodologique : les émissions GES seront réalisées selon une approche de type « location based », en cohérence avec les principes méthodologiques de l'ACV.



L'indicateur « Utilisation d'eau » des projets IA est intégré :

- ✓ **Indicateur très compréhensible** par les futurs utilisateurs de la calculatrice
- ✗ Ne répond pas au besoin de couvrir un risque de report d'impact (corrélation forte avec les indicateurs « potentiel de réchauffement climatique » et « électricité »)
- ✗ Peu de plus-value additionnelle en termes d'activation de leviers d'éco-conception

L'évaluation écarte la modélisation des toutes les autres indicateurs environnementaux d'une ACV

(trop forte complexification pour les futurs utilisateurs de l'outil, pas de plus-value en termes d'activation de leviers d'éco-conception)

3

Périmètre fonctionnel

Panorama des fournisseurs d’IA Générative, de leurs modèles et des principaux cas d’usage au sein du Groupe SNCF

Vue des fournisseurs d’IA mobilisés et leurs usages

Fournisseurs	Nb de modèles cités
 OpenAI	22 GPT-5.1, GPT-5, GPT-4.1, o3,, etc.
ANTHROPIC	8 Claude Sonnet ; Claude Haiku
 MISTRAL AI_	10 Mistral (médium et large) ; Magistral; Pixtral ; Codestral
	3 Gemini 2.5 (pro et flash, flash image)

*Volume recensé en janvier 2026 pour les projets identifiés, en production et nous ayant partagé des données de consommation

4

Synthèse de la méthodologie

La méthodologie de calcul a été conçue en quatre phases

1

Cartographier le cycle de vie d'un modèle d'IA : des recherches ont permis de lister toutes les étapes nécessaires à l'existence et au fonctionnement des composants IA (entraînement du modèle, ajout d'une base de données, fonctionnement des serveurs...). Chaque étape est à l'origine d'impacts environnementaux qui peuvent être mesurés à chaque utilisation du composant IA. – [voir le détail du cycle de vie ici](#)

Cette phase répond à la question : **qu'est-ce qui pourrait être mesuré ?**

2

Sélectionner les étapes de cycle de vie qu'il est pertinent de modéliser : un premier calcul simplifié a permis de ne conserver uniquement les étapes qui contribuent de manière significative au résultat d'impact final, pour ne pas complexifier le calcul. – [voir le détail des macros-estimations ici](#)

Cette phase répond à la question : **qu'est-ce qu'il est utile de mesurer ?**

3

Evaluer les méthodologies de calcul d'impact existantes pour ces étapes : pour les étapes conservées, des méthodologies de calcul d'impact existaient parfois. Par exemple, Ecogits est un outil ouvert de calcul de l'impact environnemental du fonctionnement des serveurs d'inférence pour la majorité des modèles d'IA type LLM. Ces méthodologies ont été évaluées pour reprendre leurs composants à jour et représentatifs de l'IA - voir plus de détails : [ici](#), [ici](#) ou [ici](#)

Cette phase répond à la question : **qu'est-ce qu'il est déjà possible de mesurer ?**

4

Concevoir et adapter des méthodologies de calcul d'impact pour les étapes restantes : pour les étapes pour lesquelles il n'existait pas de méthodologie directement exploitable, il a été nécessaire de s'appuyer sur des travaux existants, puis de les adapter, compléter, prolonger et consolider, à partir de données publiques (de consommation électrique, de composition des serveurs...) afin de les rendre cohérentes dans notre cadre d'analyse.

Cette phase répond à la question : **comment mesurer ce qui ne l'est pas encore ?**

La méthodologie de calcul d'impact environnemental suit le même principe pour toutes les étapes de cycle de vie

Pour les étapes de cycle de vie considérées comme significatives et modélisées sur Impact'IA, le travail méthodologique consiste à répondre à deux problématiques :

Données : comment modéliser l'impact environnemental de l'étape de cycle de vie ?

Ex : quel est l'impact de l'entraînement des modèles d'IA ? Du fonctionnement des serveurs qui hébergent les modèles ? Du stockage d'1 Go de donnée ?

Pour répondre à ces questions, **Impact'IA se base sur des données disponibles publiquement ou issues de ResilioDB :**

- Puissance électrique d'un serveur, d'un routeur, d'un HDD, d'un GPU...
- Durée de vie moyenne d'un serveur, d'un GPU...
- Nombre de GPU par serveur
- Consommation électrique et en eau des centres de données
- Durée d'entraînement de différents modèles d'IA
- Quantité de donnée utilisée pour entraîner les modèles d'IA
- Nombre de paramètres des modèles d'IA
- ...

→ Ces données servent de base pour calculer des consommations électriques de chaque étape de cycle de vie, et en déduire les émissions de gaz à effet de serre et la consommation d'eau.

Méthode : comment allouer cet impact à un seul token (d'entrée, de sortie, ou d'embedding) ?

Ex : quelle proportion de l'impact de l'entraînement peut être attribuée pour la consommation du projet ? Quelle proportion de la consommation électrique d'un serveur a été nécessaire au traitement d'une requête par le modèle d'IA ?

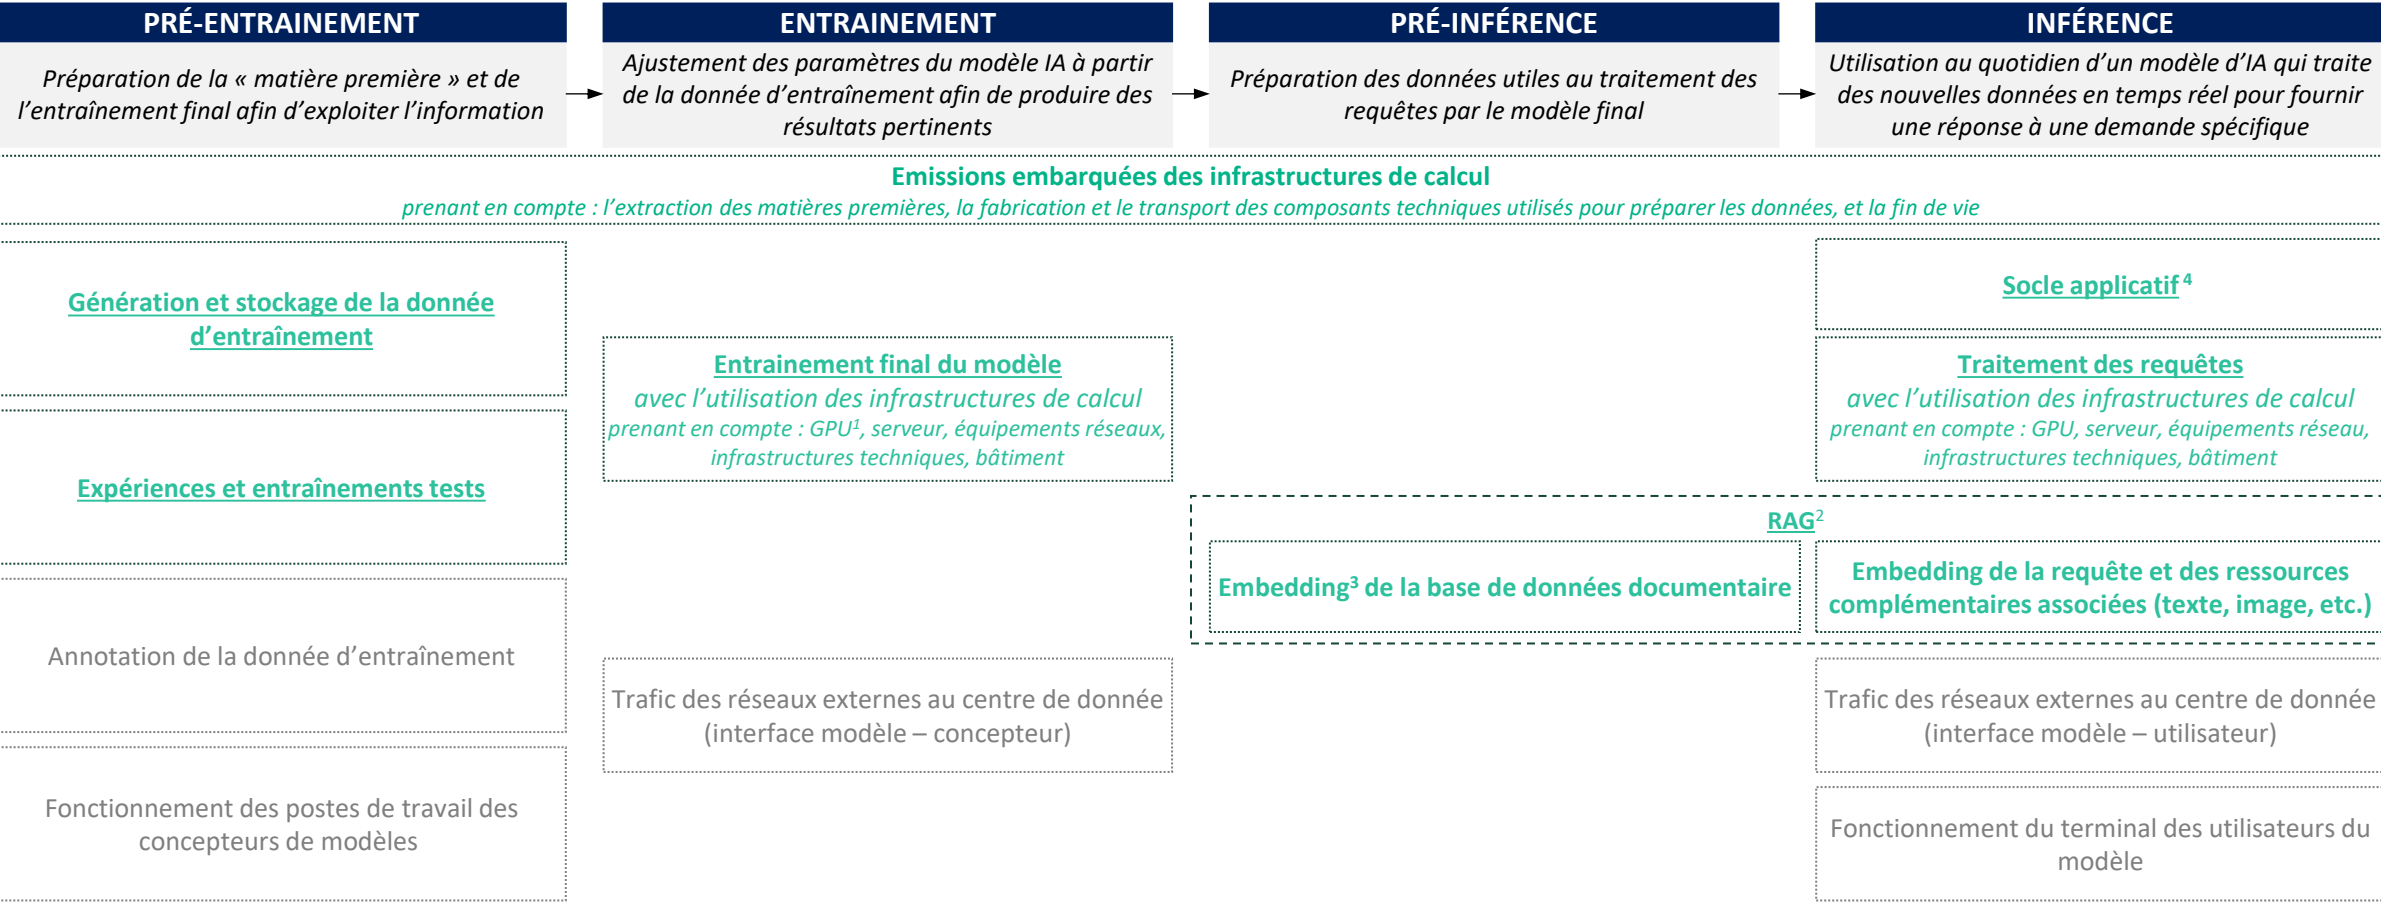
Deux approches permettent de répondre à ces questions :

- **Temporelle** : il est souvent possible d'approximer le temps nécessaire au traitement d'un token par un serveur, en fonction du modèle d'IA. L'impact environnemental est alors déduit de la durée d'utilisation des appareils.
- **Proportionnelle** : pour l'entraînement et le socle applicatif, il est possible d'approximer le nombre total de tokens dépendants de ces étapes (*ex: combien de tokens générés découle de l'entraînement d'un modèle*). L'impact environnemental est alors déduit du poids relatif d'un token sur ce total.

→ Ces méthodes permettent de calculer, à partir des données de modélisation, un résultat d'impact par token. Le total d'impact est ensuite proportionnel au nombre de tokens

Impact'IA couvre un périmètre plus large que les approches open source, avec une priorisation a priori des usages les plus impactants

Les sous-étapes modélisées correspondent à celles présentant des ordres de grandeur significatifs et actionnables directement. Leurs macro-estimations sont précisées dès la page suivante.



Légende :

Dans le périmètre de la modélisation

Hors périmètre de la modélisation

¹ GPU : Processeur graphique spécialisé conçu pour effectuer les calculs massifs, et faire fonctionner les modèles IA

² RAG (Retrieval-Augmented Generation) : Génération de réponses enrichies par une base de documents interne

³ Embedding : Traduction des documents en suite de nombre (vecteur) permettant la comparaison des contenus

⁴ Socle applicatif : Outils de support assurant le stockage des conversations, l'hébergement de la base documentaire sur des serveurs

Synthèse des ordres de grandeurs d’impact selon les étapes du cycle de vie d’une IA

Socle des choix méthodologiques, cette synthèse vise à **comparer, à grands traits, l’impact des différentes étapes du cycle de vie d’un système IA afin de disposer d’une estimation macro des ordres de grandeur et prioriser les sous-étapes significatives à intégrer (ou non) dans la modélisation. Il ne s’agit pas d’une analyse exhaustive mais d’un outil de cadrage.**

Etapes	Sous étapes du cycle de vie	Modélisé	Impact macro GES estimé	Justifications et sources
PRÉ-ENTRAÎNEMENT	Postes de travail des concepteurs de modèles	Non	0,06% de l'empreinte de l’inférence LLM	Aubakirova et al., 2025 – State of AI, An Empirical 100 Trillion Token Study with OpenRouter
	Génération et stockage de la donnée d’entraînement	Oui	9% de l'empreinte de l’inférence LLM	Glenn’s Digital Garden, 2026 – LLM training datasets Zhang et al., 2025 - MM-RLHF: The Next Step Forward in Multimodal LLM Alignment
	Annotation de la donnée d’entraînement	Non	0,1% de l'empreinte de l’inférence LLM	Zhang et al., 2025 - MM-RLHF: The Next Step Forward in Multimodal LLM Alignment
	Expérimentations et entraînements tests	Oui	200% de l’empreinte de l’inférence LLM	Epoch AI, 2025 - Most of OpenAI’s 2024 compute went to experiments
ENTRAÎNEMENT	Entraînement final des modèles	Oui	200% de l’empreinte de l’inférence LLM	Mistral AI, 2025 - Our contribution to a global environmental standard for AI Aubakirova et al., 2025 – State of AI, An Empirical 100 Trillion Token Study with OpenRouter
PRÉ-INFÉRENCE	Embedding sur base de données (RAG)	Oui	Entre 7% et 25% de l’empreinte de l’inférence LLM	Ciancone et al., 2025 - ChunkNorris: A High-Performance and Low-Energy Approach to PDF Parsing and Chunking Données de pricing de GPT et volumes de embedding venant de IA Studio
INFÉRENCE	Socle applicatif	Oui	26% de l'empreinte de l’inférence LLM	L’architecture du Socle IA est composée de 13 nœuds de 4vcpu et 16 GB RAM
	Traitement des requêtes (Prefill / Decode)	Oui	Entre 5% et 10% de l’empreinte de l’inférence LLM	Dimensionnant pour l’ensemble des projets, les données viennent de l'utilisation de IA Impact avec les données de IA Studio de Mars
	Type de traitement des requêtes Génération d’image + reasoning + code completion + speech to texte + text to speech	Non	Entre 100 % (transcription) à 1000 % (génération d’image) de l’empreinte de l’inférence LLM (texte standard).	El Bahri et al., 2025 - Comparative Analysis of Energy Consumption and Carbon Footprint in Automatic Speech Recognition Systems : A Case Study Comparing Whisper and Google Speech-to-Text et Huggingface, 2025 - AIEnergyScore Leaderboard et Communiqué de la nouvelle version Groupe SNCF GPT 2.3.2 (février) Ayant concentré nos efforts sur le training et l’inférence en text-to-text, ces valeurs n’ont pas été vérifiées
	Trafic des réseaux externes au centre de donnée	Non	4% de l'impact de l’inférence LLM	L’impact est faible et les leviers en dehors du champ d’action des chefs de projet
	Fonctionnement du terminal utilisateur	Non	10% de l'empreinte de l’inférence LLM	Cet impact n’étant pas lié à ce projet mais à une démarche d’écoconception plus globale, nous décidons de l’écarter. On suppose qu’on utilise un laptop de 65W pendant 30s en France (50g CO2e / kWh) pour une requête de 400 tokens).

Les détails des macro-estimations et des modélisations se trouvent dans les pages suivantes.

5

Modélisation détaillée

Comment lire la section « Modélisation détaillée » ?

La calculatrice Impact'IA repose sur une **approche modulaire**, dans laquelle chaque étape du cycle de vie de l'IA est modélisée selon une chaîne de calcul :

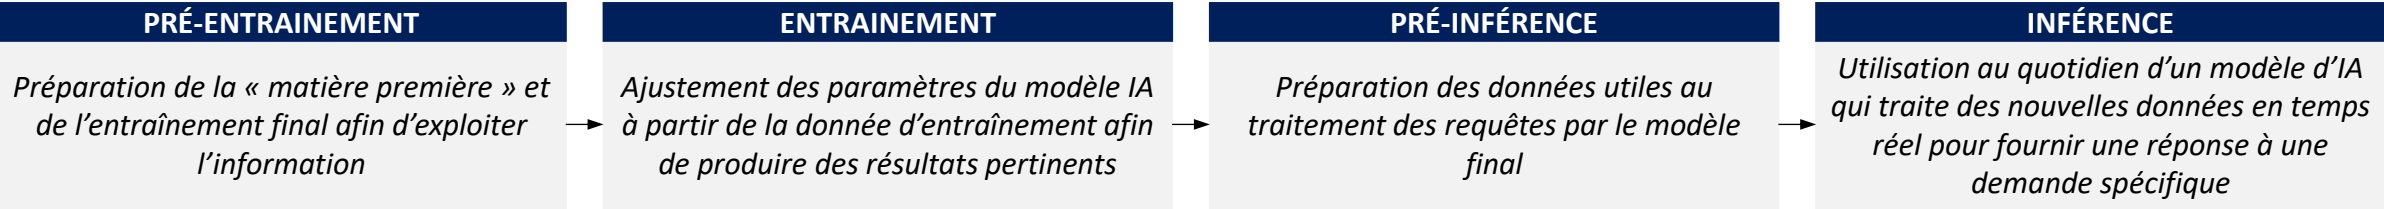


Pour chaque sous-étape jugée significative et actionnable, la modélisation suit systématiquement :

- Une **méthodologie et des hypothèses de départ documentées**,
- Une **formule issue de travaux de recherche**,
- Une **allocation au projet étudié**,
- Une **conversion en indicateurs environnementaux** (cf. [Les indicateurs environnementaux choisis...](#))

Les variables notées en *italique* sont **définies lors de leur première apparition**, puis réutilisées de manière cohérente dans l'ensemble du guide (cf. [Glossaire de la section « Modélisation détaillée »](#))

Sommaire



Pré-entraînement | Détails des ordres de grandeurs

Sous étapes	Modélisé ?	Impact macro GES estimé (et part relative)	Justifications et sources	Détail à la page
Postes de travail des concepteurs de modèles	Non	L'impact des postes de travail de 50 développeurs de Mistral est estimé à 70 kgCO2e par poste, soit 3,5 tCO2e équivalent à 0,06% de l'empreinte de l'inférence LLM	L'impact marginal par inférence de Mistral est de 3 mg / token. On estime qu'il y a 2 Trillions de tokens générés derrière. L'étude de Mistral montre le faible impact de cette partie du périmètre. Aubakirova et al., 2025 – State of AI, An Empirical 100 Trillion Token Study with OpenRouter	-
Génération et stockage de la donnée d'entraînement	Oui	Avec une taille du corpus dataset estimée à 50 000 TB de données, et un stockage en froid, on a un impact estimé à 530 tCO2e équivalent à 9% de l'empreinte de l'inférence LLM	Glenn's Digital Garden, 2026 – LLM training datasets Zhang et al., 2025 - MM-RLHF: The Next Step Forward in Multimodal LLM Alignment Attribution de 100% de stockage à ces 2T de tokens	ICI
Annotation de la donnée d'entraînement	Non	On considère 50 000h d'annotation, soit proche de 20-30 PC 8h/220jours, moins que le nombre de développeurs de Mistral soit inférieur au 0,1% de l'empreinte de l'inférence LLM	Zhang et al., 2025 - MM-RLHF: The Next Step Forward in Multimodal LLM Alignment	-
Expérimentations et entraînements tests	Oui	Par exemple, les coûts de R&D d'OpenAI sont 10 fois plus importants que l'entraînement (final) ce qui implique des dépenses de pré-entraînements par modèle d'au moins la valeur de ce dernier (au moins 14 000 tCO2e) Soit plus de 200% de l'empreinte de l'inférence LLM	Epoch AI, 2025 - Most of OpenAI's 2024 compute went to experiments	ICI

 MISTRAL AI_	Impact estimé par ACV Carbone 4 (pour l'inférence)	Conversion par token	Empreinte pour l'inférence (1 an)
Nombre de tokens	400	1	2 Trillions
Impact GES	1 gCO2e	3 mgCO2e	6000 tCO2eq

Pré-entraînement | Génération et stockage de la donnée d'entrainement (1/3)

Mise en perspective sur l’historique de la recherche documentaire

Avant de détailler l’approche retenue, une analyse de la littérature existante a été menée afin d’identifier les méthodes déjà utilisées pour estimer le rapport entre le nombre de paramètre et le volume des données utilisées à l’entrainement des grands modèles d’IA.

Approche 1 | Utilisation des données communiquées par les fournisseurs de modèle.

Actuellement, cette approche a été **écartée dû à plusieurs limites** concernant les données qui : ne sont pas systématiques publiées, ne sont pas homogènes d’un acteur à l’autre et sont souvent spécifiques à un modèle donné.

Approche 2 | Application directe de la loi de scaling

Utilisée initialement pour cadrer nos travaux, cette approche repose sur ceux de DeepMind ([Hoffmann et al., 2022 – Chinchilla](#)), selon lesquelles un modèle est entraîné de manière optimale lorsque le nombre de tokens est proportionnel (x 20) au nombre de paramètres totaux du modèle. Cette relation permet d’obtenir rapidement un ordre de grandeur du volume de données, à partir du nombre de paramètre du modèle. Cependant, il existe des **limites à cette approche** qui :

- Correspond à un optimum théorique, peu respecté en pratique (comme le démontre le tableau ci-dessous)
- Ne tient pas compte de l’évolution historique des usages et des volumes de données (comme le suggère cet [article d’Epoch AI](#))
- Ne permet pas de relier directement les tokens aux ressources de calcul et de stockage mobilisées.


Source	OpenAI – GPT-3	Open AI – GPT-4	Meta – LLaMA 3	Gemini – PaLM 2022
Taille du dataset (en milliards de token)	300	10 000 – 20 000	15 000	780
Nombre de paramètres du modèle final (en milliards)	175	1 800	8 000	540

Approche retenue | Approximation basée sur le nombre d’opération de calcul par seconde (FLOPS)

Au regard des limites des approches 1 et 2, cette 3^{ème} approche **combine les enseignements de la littérature existante avec une modélisation descendante fondée sur les capacités de calcul mobilisées**. Elle permet de dépasser les limites des approches théoriques, en offrant un cadre cohérent, transparent et reproductible pour estimer les volumes de données, les ressources de stockage et les impacts environnementaux associés à l’entraînement des modèles d’IA.



Les pages suivantes détaillent la déclinaison opérationnelle de cette approche.



Pré-entraînement | Génération et stockage de la donnée d'entraînement (2/3)

Cette section décrit l'approche 3 utilisée pour **estimer de manière progressive : le nombre de tokens nécessaires à l'entraînement d'un modèle**, le volume de données à stocker, les ressources matérielles mobilisées (HDD) puis les impacts associés. L'approche part des besoins de calcul du modèle et descend jusqu'aux infrastructures de stockage.

1 | Estimation du nombre de tokens nécessaires pour l'entraînement du modèle (notée $\#Token_{ent}$ - [sans unité])

L'entraînement d'un modèle d'IA consiste à effectuer un très grand nombre d'opération de calcul par seconde (appelée FLOPS¹). On peut relier le volume total de FLOPS requis pour l'entraînement au nombre de tokens utilisés pour l'entraînement, au travers de cette formule ([Kaplan - 2020, Scaling Laws for Neural Language Models](#)) :

Avec :

$$\#Token_{ent} = \frac{FLOPS_{ent}}{6 * P_{actif|moyenne}}$$

- **$FLOPS_{ent}$** - [en FLOPS] : Nombre de FLOPS (opération de calcul par seconde) générées pour l'entraînement final (formule détaillée à la sous-étape « [Entraînement final](#) »)
- **$Paramètres_{actif|moyenne}$** - [sans unité] : Nombre moyen de paramètres actifs du modèle

2 | Conversion du nombre de tokens en volume de données stockées (noté $Volume_{stockage}$ - [en To])

Une fois le nombre total de tokens connu, il est possible d'estimer le volume de données stockées en convertissant les tokens en caractères, puis en bits, en téraoctets.

Les hypothèses retenues sont :

- 4 caractères par token (source : [OpenAI](#))
- 1 caractère encodé sur 32 bits

$$Volume_{stockage} = \frac{\frac{\#Token_{ent} * 4 * 32}{8}}{1024^4}$$

3 | Estimation du nombre de disques durs nécessaire au stockage de la donnée (noté N_{HDD} - [sans unité])

A partir du volume de données à stocker, on peut estimer le nombre de disque durs requis (nommé HDD) en répartissant le volume total de données sur la capacité de stockage des disques. En supposant l'utilisation du HDD *Seagate Exos 30 TB*, le nombre de disques est calculé par :

$$N_{HDD} = \frac{Volume_{stockage}}{30}$$

¹ FLOPS (Floating Point Operations Per Second) : vitesse de calcul d'un système informatique, indiquant le nombre d'opérations mathématiques simples qu'un ordinateur peut effectuer en une seconde.

Pré-entraînement | Génération et stockage de la donnée d'entraînement (3/3)

Etape 4 | Consommation électrique liée au stockage des données (notée E_{stockage} - [en kWh])

Le stockage des données sur disque dur entraîne une consommation électrique continue, proportionnelle : à la puissance unitaire des HDD, au nombre de HDD, à leur taux d'utilisation, à la durée de l'entraînement. La consommation électrique attribuable au projet est estimée par

$$E_{\text{stockage}} = \frac{P_{\text{HDD}} * N_{\text{HDD}} * \text{Ratio}_{\text{HDD}} * PUE * \text{Durée}_{\text{ent}}}{\#Token_{\text{modele}}} * \#Token_{\text{sortie}}$$

Avec :

- P_{HDD} - [en kW] : Puissance électrique du HDD (estimée à 0,0095 kW)
- $\text{Ratio}_{\text{HDD}}$ - [sans unité] : Taux moyen d'utilisation du HDD sur sa durée de vie (estimé à 20%)
- PUE (Power Usage Efficiency) - [sans unité] : Indicateur d'efficacité énergétique du centre de données (variable selon la localisation des fournisseurs entre 1,09 et 1,2)
- $\text{Durée}_{\text{ent}}$ - [en heure] : Durée de l'entraînement du modèle (estimée à 100 jours)
- $\#Token_{\text{sortie}}$ - [sans unité] : Nombre de tokens de sortie par le projet (sur 1 an)
- $\#Token_{\text{modele}}$ - [sans unité] : Nombre de tokens générés en inférence par le modèle (sur 1 an) (formule détaillée à la sous-étape « [Inférence](#) »)

Etape 5 | Calcul des impacts environnementaux du stockage ($I_{\text{stockage}}^{\text{GWP}}$ - [en kg CO₂e] et $I_{\text{stockage}}^{\text{WU}}$ - [en m³ eq])

Une fois la consommation électrique et le nombre de HDD connus, les impacts environnementaux (GWP et WU) du stockage des données peuvent être estimés à l'aide des facteurs issus de la base ResilioDB. L'impact du stockage est calculé en amortissant au prorata du nombre de tokens de sortie du projet :

Les hypothèses retenues sont :

- Durée de vie du HDD (DV_{HDD} - [en heure]) estimée à 5 ans
- Localisation des infrastructures : Monde
- $I_{\text{HDD}}^{\text{emb}}$: Impacts (GWP - [en kg CO₂e] et WU - [en m³ eq]) embarqués d'un HDD¹

$$I_{\text{stockage}} = (E_{\text{stockage}} * FE_{\text{Monde}}) + \left(\frac{\left(\frac{I_{\text{HDD}}^{\text{emb}}}{DV_{\text{HDD}}} \right) * N_{\text{HDD}} * \text{Durée}_{\text{ent}}}{\#Token_{\text{modele}}} \right) * \#Token_{\text{sortie}}$$

¹ ResilioDB - model hash : a6732f1d11a526d6818449833d73a613672d54918ad5112c0b4b4c077de485b6

Pré-entraînement | Expérimentations et entraînements tests (R&D)

Les phases d'expérimentation et d'entraînement tests menées au préalable de l'entraînement final du modèle correspondent aux activités de recherche et développement (R&D) : essais, ajustement et itération nécessaires à la mise au point d'un modèle opérationnel. Compte tenu de la forte incertitude (peu documentées), **l'approche retenue se veut prudente et conservatrice**, en reliant les activités de R&D à l'entraînement final du modèle sur des ratios issus de la littérature.

Etape 1 | Estimation de la consommation électrique de la R&D attribuable au projet étudié (notée $E_{R\&D}$ - [en kWh])

Afin de rester cohérent avec les intervalles de confiance (IC) observés dans la littérature, nous retenons que la consommation électrique la R&D est estimée comme un multiple de celle de l'entraînement final (noté $E_{ent|projet}$ - [en kWh] et formule détaillée à la sous-étape « Entraînement final ») et le facteur 4 correspond à une valeur conservatrice, située dans la fourchette médiane des ordres de grandeurs identifiés :

$$E_{R\&D} = 4 * E_{ent|projet}$$

Etape 2 | Conversion de la consommation électrique en impact climatique de la R&D (noté $I_{R\&D}^{GWP}$ - [en kg CO2e])

Une fois l'électricité consommée estimée, l'impact climatique est calculé en appliquant un facteur d'émission électrique moyen mondiale (noté FE_{monde} - [en kg CO2e / kWh] et estimé à 0,47301 kg CO2e / kWh), cohérent avec l'hypothèse d'une localisation des infrastructures à l'échelle mondiale.

$$I_{R\&D}^{GWP} = E_{R\&D} * FE_{monde}$$

Etape 3 | Estimation de l'impact de l'utilisation d'eau de la R&D (noté $I_{R\&D}^{WU}$ - [en m³ eq])

De manière analogue, l'impact sur l'eau est estimé à partir de la consommation électrique, d'un facteur d'utilisation d'eau lié au modèle (noté WU_{modele} - [en m³ eq] et variable selon la localisation du fournisseur) et d'un coefficient de disponibilité de l'eau (noté $Aware$ - [sans unité] et estimé à 1,4)

$$I_{R\&D}^{WU} = E_{R\&D} * WU_{modele} * Aware$$

Synthèse de la recherche documentaire	OpenAI (2024)	MiniMax (2025)	Z.ai (2024 – 2025)
Part de la dépense totale liée à la R&D	90% (4,5 Md\$ sur 4,98 Md\$)	77,4% (sur 141 M\$)	87,7% (sur 216 M\$)
Facteur R&D (Intervalle de Confiance)	9 (IC 90% : 2,5 – 19)	4,42 (IC 90% : 1 – 9)	8,13 (IC 90% : 3 – 19)
Commentaires	Pour toute l'année 2024, inclus les modèles GPT 4.5, 4o, Sora Turbo, la série o, et d'autres petits modèles.	8,2 si on ignore les modèles Hailuo avec un fort taux d'incertitude.	-

Nota : Un facteur de 0,51 n'a pas été retenu car les travaux [académiques](#) associés portent sur l'étude de modèles de très petite taille, non représentatifs des pratiques actuelles.



Entraînement | Détails des ordres de grandeurs

Sous étapes	Modélisé ?	Impact macro GES estimé (et part relative)	Justifications et sources	Détail à la page
Entraînement final des modèles	Oui	D'après Mistral, training et inférence sont 20 000 tCO2e, dont 14 000 tCO2e pour le training, ou plus de deux fois l'impact de l'inférence, et donc significatif Soit plus de 200% de l’empreinte de l’inférence LLM	Supposons que 2T de tokens sont générés par Mistral Large 2 après 18 mois en phase d’inférence. Avec un impact marginal de 0,003g /token, on a 6 000 t CO2e pour la phase d’inférence. Mistral AI, 2025 - Our contribution to a global environmental standard for AI https://openrouter.ai/state-of-ai	ICI

	Impact estimé par ACV Carbone 4 (pour l’inférence)	Conversion par token	Empreinte pour l’inférence (1 an)
 Nombre de tokens	400	1	2 Trillions
Impact GES	1 gCO2e	3 mgCO2e	6000 tCO2eq

Entraînement | Estimation top-down des opérations de calcul - FLOPS (1/3)

Cette section détaille l'approche utilisée pour estimer le volume d'opération de calcul par seconde (appelée FLOPS), puis en déduire la consommation électrique et les impacts environnementaux. L'approche retenue est top-down, se basant sur le volume de FLOPS, puis le convertit progressivement en énergie, avant d'allouer cette énergie au projet étudié.

Étape 1 | Estimation du volume de FLOPS nécessaires pour l'entraînement final du modèle (noté $FLOPS_{ent}$ - [en FLOPS])

L'entraînement final d'un modèle consiste à exécuter un grand nombre d'opération mathématiques. Sur la base des datasets des [travaux publiés par Epoch AI](#), nous de prendre en compte la dimension temporelle. Le coefficient temporel (ici 0,0006) peut être ajusté à 0,017 si on estime une augmentation plus importante des frontier models en FLOPS. La formule utilisée est la suivante :

$$FLOPS_{ent} = 10^{(0,0006 * Durée_{modèle} + 17,1510)} * Paramètres_{total}^{0,5410}$$

Avec :

- $Durée_{modèle}$ - [en jour]: Nombre de jours entre le 1^{er} janvier 2020 et la date de publication du modèle (variable selon le modèle)
- $Paramètres_{total}$ - [sans unité]: Nombre total de paramètres du modèle (en inférence)

La première partie représente l'augmentation tendancielle de la complexité des modèles dans le temps : **à taille comparable, les modèles les plus récents nécessitent plus de calcul.** La seconde partie traduit le fait que **plus un modèle comporte de paramètres actifs, plus l'entraînement est couteux en FLOPS.**

Étape 2 | Conversion du calcul en consommation électrique totale de l'entraînement final (noté $E_{ent|global}$ - [en kWh])

Une fois le nombre de FLOPS estimé, l'objectif est de le transformer en consommation électrique. Pour cela, on estime l'énergie consommé par FLOPS (notée $E_{par FLOPS}$), à l'aide d'un approche top-down (image ci-dessous) en rapportant la consommation électrique globale d'un centre de données à la quantité de calcul qu'il délivre. Sur la base d'une [valeur de référence publiée par Epoch AI](#), l'efficacité énergétique du calcul (notée $FLOPS_{par watt}$) est estimée à $1,4 * 10^{12}$ FLOP par seconde et par watt (en FLOPS/watt). La consommation électrique totale liée à l'entraînement est alors donnée par :

Top-down



$$E_{ent|global} = \left(R_{inférence} * \frac{FLOPS_{ent} * E_{par FLOPS}}{3600} \right) * PUE$$

Avec :

- $FLOPS_{ent}$ - [en FLOPS]
- $E_{par FLOPS}$ - [en watt]: Electricité consommée par FLOPS (estimée à $\frac{1}{1,4 * 10^{12}}$ W)
- PUE - [sans unité]
- $R_{inférence}$ - [sans unité] : Facteur d'extension d'infrastructure équivalent à $\frac{E_{GPU} + E_{serveur} + E_{réseau}}{E_{GPU|inférence}}$

En l'absence de données complètes sur les consommations auxiliaires de la phase d'entraînement, un facteur d'extension d'infrastructure (noté $R_{inférence}$) a été appliqué à la consommation électrique estimée du calcul GPU. Ce facteur est dérivé de la répartition énergétique observée lors de la phase d'inférence, afin de maintenir un périmètre technique homogène entre les différentes phases du cycle de vie

Entraînement | Estimation top-down des opérations de calcul – FLOPS (2/3)

Etape 3 | Allocation de la consommation électrique de l'entraînement final attribuable au projet étudié (notée $E_{ent|projet}$ - [en kWh])

L'entraînement final d'un modèle bénéficie généralement à plusieurs usages. Il est donc nécessaire d'allouer une partie de cette consommation totale au projet étudié.

Cette allocation est réalisée au prorata du nombre de tokens utilisés par le projet, selon la formule :

$$E_{ent|projet} = \frac{E_{ent|global}}{\#Token_{modele}} * \#Token_{sortie}$$

Avec :

- $E_{ent|global}$ - [en kWh]
- $\#Token_{sortie}$ - [sans unité]
- $\#Token_{modele}$ - [sans unité]

Etape 4 | Calcul des impacts environnementaux (notés $I_{ent|projet}$ avec GWP - [en kg CO₂e] et WU - [en m³ eq])

Une fois l'électricité attribuée au projet, les impacts environnementaux sont calculés à l'aide de facteur d'impact suivant les indicateurs GWP et WU. Les hypothèses retenues sont :

- Localisation des infrastructures de calcul : Monde
- Utilisation de ratios issus des calculs d'inférence pour estimer les impacts embarqués et les impacts de l'environnement de calcul

$$I_{ent|projet}^{GWP} = E_{ent|projet} * \left[FE_{Monde} + \frac{I_{inférence}^{emb}}{E_{inférence}} \right]$$

Avec :

- $E_{ent|projet}$ - [en kWh]
- FE_{Monde} - [en kg CO₂e / kWh]
- $E_{inférence}$ - [en kWh] : Consommation électrique totale de la phase d'inférence du projet
- $I_{inférence}^{emb}$ (GWP - [en kg CO₂e] et WU - [en m³ eq]) : Impacts embarqués (hors usage) de la phase d'inférence du projet
- WU_{modele} - [en m³ eq]
- $Aware$ - [sans unité]


$$I_{ent|projet}^{WU} = E_{ent|projet} * \left[(WU_{modele} * Aware) + \frac{I_{inférence}^{embarquée}}{E_{inférence}} \right]$$

Entraînement | Estimation top-down des opérations de calcul – FLOPS (3/3)

Mise en perspective des 2 approches identifiées lors de la recherche documentaire

Approche 1 | GPU mobilisés et leur durée d'utilisation ([Falk et al., 2025 – Environmental impacts of GenAI training - A100](#))

Cette approche a été écartée, bien que détaillée, nécessite des hypothèses fines souvent indisponibles (nombre de GPU, configurations de serveur, taux d'usage)



$\#GPU_{active}$: Number of GPUs actively used during training.

$\#GPU_{installed}$: Number of GPUs installed in a server.


$W_{server\backslash GPU}$: Power consumption of non-GPU components in a server.

$FLOPs_{train}$: Total number of FLOPs required for training.

$FLOPs_{GPU}$: Compute throughput per GPU (FLOPs per second).

Approche retenue | Lien entre paramètres, FLOPS et énergie ([Epoch AI; d'Orgeval et al., 2026 – LCA of GenAI data centers](#))

Cette approche est plus robuste et pourra plus facilement s'adapter à de nouveaux usages d'IA, basés par exemple sur des modèles plus petits.



E_{train} : Total energy consumed to train the model.

$FLOPs_{train}$: Total number of FLOPs required for training.

E_{FLOP} : Energy consumed per single FLOP.

$\#P_{model}$: Number of parameters in the model.

$\#T_{train}$: Number of training tokens.

$E_{datacenter}$: Total energy consumed by the datacenter over its lifetime.

$FLOPs_{datacenter}$: Total number of FLOPs produced by the datacenter over its lifetime.

$PeakFLOPs$: Maximum theoretical compute throughput of the hardware over time (FLOPs per second).

ΔL : lifespan of the datacenter.

$LoadRate$: Utilization factor (how much of the peak compute is actually used, between 0 and 1).



Pré-inférence | Détails des ordres de grandeurs

Sous étapes	Modélisé ?	Impact macro GES estimé (et part relative)	Justifications et sources	Détail à la page
Embedding sur base de données (RAG)	Oui	Le parsing de 200 000 documents équivaut à environ 1 kWh, soit près de 50 gCO₂e. Le chunking a, en comparaison, un impact négligeable par rapport au parsing. Quant à la phase d’embedding, son coût par token est 13 à 50 fois inférieur à celui de l’inférence GPT-4, même si, d’après les données d’IA Studio, son usage est trois fois plus important que celui des requêtes d’entrée/sortie. Soit entre 7% et 25% de l’empreinte de l’inférence LLM	Ciancone et al., 2025 - ChunkNorris: A High-Performance and Low-Energy Approach to PDF Parsing and Chunking On utilise aussi les données de pricing de GPT et les volumes de embedding venant de IA Studio	ICI

	Impact estimé par ACV Carbone 4 (pour l’inférence)	Conversion par token	Empreinte pour l’inférence (1 an)
 MISTRAL AI			
Nombre de tokens	400	1	2 Trillions
Impact GES	1 gCO ₂ e	3 mgCO ₂ e	6000 tCO ₂ eq

Pré-inférence | RAG Engine / Embedding (1/4)

L'embedding correspond à la transformation des textes en vecteurs numériques, afin de permettre leur recherche et leur exploitation par le modèle. Cette partie vise à estimer la phase d'embedding des données d'entrée dans un système de type RAG (Retrieval-Augmented Generation). L'approche consiste à calculer le temps de calcul nécessaire (latence) pour effectuer l'embedding, le convertir en consommation électrique et en impacts environnementaux.

Étape 1 | Estimation du temps de latence liée à l'embedding (noté $Latence_{RAG}$ - [en seconde])

Les travaux analysés montrent qu'il est possible d'estimer le temps de latence lié à l'embedding des tokens d'entrée, même si l'embedding de l'ensemble des documents sources n'est pas modélisé ici. A partir des données du modèle Qwen3-8B (graphique), une relation empirique est proposée :

$$Latence_{Qwen3-8B} = 0,022 * [\#Token_{RAG} * Batch] + 97,394$$

Afin de rendre la formule applicable à d'autres modèles d'embedding, elle est ajustée en fonction du nombre total de paramètres du modèle, via un ratio comparatif :


$$Latence_{RAG} = 0,022 * \frac{Paramètres_{total}}{8 * 10^9} * [\#Token_{RAG} * Batch] + 97,394$$

Avec :

- **$Paramètres_{total}$** - [sans unité]
- **$\#Token_{RAG}$** - [sans unité] : Nombre de tokens d'entrée du RAG sur 1 an
- **$Batch$** - [sans unité] : Nombre de requêtes traitée en parallèle (estimé à 64)

En prenant comme hypothèses :

- Modèle de référence: Qwen3-8b (8 milliards de paramètres)
- Caractéristiques du modèle d'embedding : text-embedding-3-large (~8 milliards de paramètres)



L'étude sur laquelle se base notre analyse permet de mieux comprendre les coûts et les performances associés au traitement des données.

Pré-inférence | RAG Engine / Embedding (2/4)

Étape 2 | Conversion de la latence en consommation électrique de la phase d'embedding (notée E_{RAG} - [en kWh])

Une fois la latence estimée, elle est convertie en consommation électrique, en tenant compte de : la puissance du serveur, la puissance du GPU, la part du réseau et l'efficacité énergétique du centre de données (PUE). La formule utilisée est :

$$E_{RAG} = N_{GPU-RAG} * \frac{Latence_{RAG}}{3600} * \left(P_{SERVEUR} + N_{GPU-RAG} * \left(P_{GPU} + \frac{P_{réseau}}{N_{GPU|serveur}} \right) \right) * \frac{1}{Batch} * PUE$$

Avec :

- **$Latence_{RAG}$** - [en seconde]
- **$P_{SERVEUR}$** - [en kW] : Puissance électrique du serveur (sans GPU) pour l'embedding (estimée à 1,2 kW)
- **$N_{GPU|RAG}$** - [sans unité] : Nombre de GPU utilisés pour l'embedding (estimé à 1)
- **P_{GPU}** - [en kW] : Puissance électrique du GPU (estimée à 0,7 kW)
- **$P_{réseau}$** - [en kW] : Puissance électrique des équipements de réseau (pares-feux, routeurs, switches) (formule détaillée à l'étape « [Inférence](#) »)
- **$N_{GPU|serveur}$** - [sans unité] : Nombre de GPU par serveur (estimé à 8)
- **$Batch$** - [sans unité]
- **PUE** - [sans unité]

Et en prenant comme hypothèse, les caractéristiques du GPU utilisé pour l'embedding : NVIDIA H100 80GB SXM5 (en cohérence avec la modélisation d'Ecologits). Les puissances GPU et serveur sont cohérentes avec les hypothèses retenues dans la section « [Inférence – Traitement des requêtes](#) ».

Pré-inférence | RAG Engine / Embedding (3/4)

Etape 3 | Calcul des impacts environnementaux (noté I_{RAG} pour GWP - [en kg CO₂e] et WU - [en m³ eq])

Une fois la consommation électrique connue, les impacts environnementaux sont calculés en distinguant : l'usage lié à l'électricité consommée et les impacts embarqués liés au reste du cycle de vie des équipements, basé sur la base ResilioDB. L'impact total est donc la somme de ces deux composantes :

$$I_{RAG}^{GWP} = E_{RAG} * \left(FE_{FR+SW} + \frac{FE_{batiment}}{PUE} \right) + \frac{Latence_{RAG}}{Batch} * \left[\left(\frac{N_{GPU|RAG}}{N_{GPU|serveur}} * \frac{I_{réseau}^{emb} * Ratio_{réseau}}{DV_{réseau}} \right) + N_{GPU|RAG} * \left(\frac{I_{serveur}^{emb}}{DV_{serveur} * N_{GPU|serveur}} \right) \right]$$

$$I_{RAG}^{WU} = (E_{RAG} * WU_{modele} * Aware) + \frac{Latence_{RAG}}{Batch} * \left[\left(\frac{N_{GPU|RAG}}{N_{GPU|serveur}} * \frac{I_{réseau}^{emb} * Ratio_{réseau}}{DV_{réseau}} \right) + N_{GPU|RAG} * \left(\frac{I_{serveur}^{emb}}{DV_{serveur} * N_{GPU|serveur}} \right) \right]$$

Avec :

- E_{RAG} - [en kWh]
- FE_{FR+SW} - [en kg CO₂e / kWh] : Facteur d'émission électrique moyenne France / Suède (estimé à 0,0408 kg CO₂e / kWh)
- $FE_{batiment}$ - [en kg CO₂e / kWh] : Impacts du bâtiment et de l'environnement technique par kWh consommé (estimé à 0,0408 kg CO₂e / kWh)
- PUE - [sans unité]
- $Latence_{RAG}$ - [en seconde]
- $Batch$ - [sans unité]
- $I_{réseau}^{emb}$ (GWP - [en kg CO₂e] et WU - [en m³ eq]) : Impacts embarqués (hors usage) des équipements de réseau (pares-feux, routeurs, switches)

- $Ratio_{réseau}$ - [sans unité] : Taux de disponibilité effective des équipements de réseau (pares-feux, routeurs, switches) sur leur durée de vie
- $DV_{réseau}$ - [en heure] : Durée de vie des équipements de réseau (pares-feux, routeurs, switches) (estimée à 5 ans)
- $N_{GPU|RAG}$ - [sans unité]
- $I_{serveur}^{emb}$ (GWP - [en kg CO₂e] et WU - [en m³ eq]) : Impacts embarqués (hors usage) du serveur¹ (avec GPU)
- $DV_{serveur}$: Durée de vie du serveur avec GPU (estimée à 3 ans)
- $N_{GPU|serveur}$ - [sans unité] : Nombre de GPU par serveur (estimé à 8)
- WU_{modele} - [en m³ eq]
- $Aware$ - [sans unité]

¹ ResilioDB - Model hash : 5fb423369eb5137d6a8bb200bce4f376977a4f5924f40f1b183b58a1d165359d / Model hash : 8648780a73eaf883086eb7e17185e4094623eeb21f08b7ab1426a1b58199146f

Pré-inférence | RAG Engine / Embedding (4/4)

Mise en perspective sur la recherche documentaire

Avant de retenir l'approche de calcul utilisée pour la phase d'embedding, la recherche documentaire s'est articulée autour de trois axes principaux :

Analyse des modèles d'embedding disponibles

Source : [MTEB Leaderboard - a Hugging Face Space by mteb](#)

Résultats : les modèles "référence" du marché - *text-embedding-3-large*, *Qwen3-Embedding-8B*, *e5-mistral-7b-instruct...* - ont des performances et un nombre de paramètres comparables

Etude la latence et du ing

Source : [Benchmarking API latency of embedding providers \(and why you should always cache your embeddings\)](#)

Résultats : La latence observée en API est indépendante de la taille de la requête ; le ing est donc systématique, et supposé optimisé pour maximiser le nombre de tokens / s traités

Mobilisation de GPU

Source : [Why are embeddings so cheap? - by Piotr Mazurek](#)

Résultats : L'embedding mobilise 1 GPU ; pour un modèle d'embedding comme Qwen3-embedding-8B, 45000 tokens d'embedding / seconde est la frontière d'optimisation, et semble correspondre à la facturation des modèles.

Approche initiale :

La formule de calcul de la consommation électrique du GPU pour l'embedding multiplie le nombre de tokens d'embedding par le temps de traitement d'un token par le GPU optimisé (soit 1/45000 de seconde), et de multiplier ce résultat par la puissance électrique des équipements.

$$Latence_{RAG} = \frac{1}{45\,000} * \# \frac{Token_{RAG}}{3600}$$

$$E_{RAG} = \left(P_{GPU} + \frac{P_{serveur}}{8} \right) * Latence_{RAG}$$

Le calcul proposé prend les hypothèses suivantes :

- Les requêtes d'embedding mobilisent 1 seul GPU de 700W de puissance électrique, intégré à un serveur de 1200W de puissance (hors GPU) pour 8GPU
- Un GPU optimisé est capable de calculer l'embedding pour 45000 tokens d'entrée par seconde
- Ce GPU est intégré à un serveur similaire aux serveurs d'inférence pris en compte pour les autres calculs de cette méthodologie

La consommation électrique de l'environnement technique est calculée de la même manière, en multipliant la puissance électrique des composants par le temps de traitement de la requête. Le total (Consommation électrique GPU + serveur + environnement technique) est multiplié par le PUE pour avoir une vision complète de la consommation électrique du centre de données.

Inférence | Détails des ordres de grandeurs

Sous étapes	Modélisé ?	Impact macro GES estimé (et part relative)	Justifications et sources	Détail à la page
Socle applicatif	Oui	Derrière tout IA Studio il y a 13 nœuds de 4vcpu et 16 GiB RAM chacun, ou 2 tCO2e par machine par an, soit 26t CO2 par an, Si on a 30B de tokens générés par IA studio sur un an, son impact à l'inférence (avec les données Mistral) est de 100t de CO2. L'impact du front applicatif représente 26% de l'empreinte de l'inférence LLM	Toute la stack technique de IA Studio, RAG, LLM est sur un nombre très faible de micro services, sur une architecture très légère.	ICI
Traitement des requêtes (Prefill / Decode)	Oui	Si on considère les données de IA Studio comme représentatives de la SNCF, l'empreinte de la partie prefill représente 5% de l'empreinte de l'inférence LLM	Reprenant les données de consommation de IA Studio pendant le mois de mars. Si on rajoute le RAG de la SNCF, le % augmente aux 6-10%.	ICI
Type de traitement des requêtes <i>Génération d'image + reasoning + code completion + speech to texte + text to speech</i>	Non	<i>Entre 100 % (transcription) à 1000 % (génération d'image) de l'empreinte de l'inférence LLM (texte standard). Ayant concentré nos efforts sur le training et l'inférence en text-to-text, ces valeurs n'ont pas été vérifiées</i>	El Bahri et al., 2025 - Comparative Analysis of Energy Consumption and Carbon Footprint in Automatic Speech Recognition Systems : A Case Study Comparing Whisper and Google Speech-to-Text Huggingface, 2025 - AIEnergyScore Leaderboard Communiqué de la nouvelle version Groupe SNCF GPT 2.3.2 (février)	-
Trafic des réseaux externes au centre de donnée	Non	L'impact marginal d'un KB de données (qui est plus grand q'un token) est autour des 1 mg/KB. Un prompt de 400 mots est estimé à 50 KB, soit 0,125 mgCO2e/token. Soit 4% de l'empreinte de l'inférence LLM	Facteur RDB: 0bb1d4db142275f766fd80318199b4c26dcde01e39199655c09371ec2ddabc0c Exclu. L'impact est très faible, ici on peut voir l'impact du réseau comme celui quand on envoie un email, presque nul.	-
Fonctionnement du terminal utilisateur	Non	Un utilisateur qui consacre 30 secondes à rédiger et lire une requête génère un impact estimé entre 2 et 4 gCO2e, ce qui est supérieur à l'impact de la requête elle-même (environ 1 gCO2e pour 400 tokens). Soit 10% de l'empreinte de l'inférence LLM	Pour un terminal à 4W de puissance, un mix à 30g /kWh . Cet impact n'étant pas lié à ce projet mais à une démarche d'écoconception plus globale, nous décidons de l'écarter	-

Inférence | Socle applicatif (1/2)

Nous faisons l'hypothèse d'un **socle applicatif regroupant l'ensemble des fonctions techniques qui entourent et supportent les appels aux modèles d'IA**, avant et après l'inférence proprement dite. Il inclurait notamment le routage des requêtes, l'orchestration des services, la gestion des utilisateurs, le stockage des conversations et des bases documentaires, ainsi que le pilotage du front applicatif.

Bien que ces briques ne réalisent pas directement le calcul du modèle, leur exécution reposerait sur des infrastructures serveurs dont la consommation électrique génèrerait des impacts environnementaux qu'il est nécessaire d'intégrer à l'évaluation globale d'une application d'IA.

Dans la pratique, l'architecture hébergeant le socle applicatif pourrait varier d'une application à l'autre. Afin de garantir la cohérence et la comparabilité des résultats, la méthodologie Impact'IA repose sur une **architecture standard de référence**, supposée représentative des usages.

À titre de référence, le socle applicatif hypothétique serait hébergé sur **13 nœuds** serveurs (vCPU et mémoire), pour un volume annuel d'environ **21 milliards de tokens générés**. Les calculs qui suivent visent à estimer l'impact environnemental associé au fonctionnement de ce socle hypothétique, puis à **l'allouer au projet étudié au prorata de son usage**, exprimé en nombre de tokens. La [page suivante](#) détaille successivement :

- le calcul de la consommation électrique du socle applicatif,
- son allocation au projet étudié,
- puis la conversion de cette consommation en impacts environnementaux.

Note méthodologique – Guardrail

Certains services transverses, comme les mécanismes de **Guardrail assurant le filtrage de contenus**, font partie du socle applicatif. Néanmoins, en raison de leur fonctionnement opaque, de leur faible consommation relative et du manque de données détaillées, leur impact est considéré comme marginal à l'échelle du périmètre étudié et **n'est pas pris en compte dans la calculatrice Impact'IA**.

Inférence | Socle applicatif (2/2)

Le socle applicatif correspondrait à l'ensemble des briques techniques permettant le fonctionnement de l'application autour du modèle d'IA. Cette section vise à estimer les impacts liés au socle applicatif supportant les usages d'inférence (hors calcul du modèle lui-même) en se basant sur les composants techniques de Socle IA.

Etape 1 | Allocation au projet étudié de la consommation électrique du socle applicatif (notée $E_{Socle|projet}$ - [en kWh])

La consommation annuelle du socle applicatif (en kWh) totale est calculée comme : $E_{Socle} = P_{noeud} * N_{noeud} * PUE$

Soit pour l'attribution au projet étudié :

Avec :

- P_{noeud} - [en kW] : Puissance électrique du nœud (estimée à 0,01 kW)
- N_{noeud} - [sans unité] : Nombre de nœud (basé sur les caractéristiques du Socle IA – 13 nœuds)

- PUE - [sans unité]
- $\#Token_{Socle}$ - [sans unité] : Nombre de token transitant par le socle applicatif annuellement (basé sur les données mensuelles du Socle IA)
- $\#Token_{sortie}$ - [sans unité]

$$E_{Socle|projet} = \frac{P_{noeud} * N_{noeud} * PUE}{\#Token_{Socle}} * \#Token_{sortie}$$

Etape 2 | Calcul des impacts environnementaux du socle applicatif attribuable au projet (noté I_{Socle} pour GWP - [en kg CO₂e] et WU - [en m³ eq])

$$I_{Socle}^{GWP} = \frac{\#Token_{sortie}}{\#Token_{Socle}} * \left(N_{noeud} * \frac{I_{noeud}^{emb.}}{DV_{noeud}} + E_{socle} * FE_{FR+SW} \right) * 24 * 365$$

Avec :

- FE_{FR+SW} - [en kg CO₂e / kWh]
- DV_{noeud} - [en heure] : Durée de vie des nœuds du socle (estimée à 4 ans)
- $I_{noeud}^{emb.}$ (GWP - [en kg CO₂e] et WU - [en m³ eq]) : Impacts embarqués (hors usage) du nœud¹
- WU_{modele} - [en m³ eq]
- $Aware$ - [sans unité]

$$I_{Socle}^{WU} = \frac{\#Token_{sortie}}{\#Token_{Socle}} * \left[(E_{socle} * WU_{modele} * Aware) + \frac{N_{noeud} * I_{noeud}^{emb.}}{DV_{noeud}} \right] * 24 * 365$$

¹ ResilioDB - Model hash : 9f4a71bae40b335f13d522e949ace0b8acfc641c987212a4198dc238d3949c0f

Inférence | Nombre de tokens générés par un modèle (1/2)

Pour estimer le nombre de tokens générés en phase d'inférence par un modèle d'IA, nous adoptons une approche top-down. En partant de la puissance de calcul globale disponible chez les fournisseurs d'IA, nous la redistribuons progressivement jusqu'à l'échelle du modèle spécifique, puis jusqu'au nombre de tokens générés. Cette approche permet d'obtenir un ordre de grandeur robuste, même lorsque les données détaillées par modèle ne sont pas publiques.

Etape 1 | Répartition de la puissance de calcul globale par modèle (notée $Compute_{modele}$ - [en kW])

Une partie de la puissance de calcul globale, dont dispose les fournisseurs d'IA, est dédiée à l'inférence et elle est mutualisée entre plusieurs modèles actifs. La capacité moyenne allouée à un modèle est estimée par :

$$Compute_{modele} = \frac{[Compute_{global} * Ratio_{inférence}]}{\#Modele_{actif}}$$

Avec :

- **$Compute_{global}$** - [en kW]: Puissance de calcul globale des fournisseurs pour leurs infrastructures IA
- **$Ratio_{inférence}$** - [sans unité] : Proportion de la puissance installée dédiée l'inférence de modèle (estimée à 20%)
- **$\#Modele_{actif}$** - [sans unité] : Nombre de modèles actifs (ayant une durée de vie de 2 ans à partir de la date de publication du modèle)

Etape 2 | Conversion de la puissance en volume de FLOPS nécessaires (volume d'opération de calcul par seconde) (noté $FLOPS_{modele}$ - [en FLOPS])

Une fois la puissance de calcul allouée à un modèle connue, le nombre de FLOPS alloués au fonctionnement du modèle est alors :

$$FLOPS_{modele} = Compute_{modele} * FLOPS_{par watt} * \epsilon_{total}$$

Avec :

- **$FLOPS_{par watt}$** - [en FLOPS / watt]
- **ϵ_{total}** - [sans unité] : Facteur pour tenir compte des conditions réelles d'utilisation de l'infrastructure (formule détaillée à la [page suivante](#))

Inférence | Nombre de tokens générés par un modèle (2/2)

Etape 2 bis | Calcul du facteur d'ajustement (noté ε_{total} - [sans unité])

$$\varepsilon_{total} = \varepsilon_{GPU\ utilisation} * \varepsilon_{limite-memoire} * \frac{1}{PUE} * \varepsilon_{GPU\ partagé}$$

avec les valeurs retenues :

$$\varepsilon_{total} = 0,5 * 0,5 * \frac{1}{1,2} * 0,7 = 0,15$$

Ce facteur permet de refléter que :

- Les GPU ne sont pas utilisés à 100% en permanence.
- Certaines limitations (mémoire, partage) réduisent la puissance.
- Une partie de l'énergie est consommée par l'infrastructure.

Etape 3 | Transformation du volume de FLOPS en nombre de tokens générés par un modèle (noté $\#Token_{modele}$ - [sans unité])

Dans les modèles LLM, il existe une relation entre le nombre de paramètre actifs du modèle et le nombre d'opération pour générer un token. On peut donc estimer le nombre de tokens générés annuellement par :

$$\#Token_{modele} = FLOPS_{modele} * \frac{365 * 24 * 3600}{2 * Paramètres_{actif|moyenne}}$$

Avec :

- $FLOPS_{modele}$ - [en FLOPS]
- $Paramètres_{actif|moyenne}$ - [sans unité]

Etape 4 | Prise en compte de la durée de vie du modèle (noté $\#Token_{modele}$)

Enfin, pour estimer le **nombre total de tokens générés sur l'ensemble de la durée de vie du modèle**, il faut multiplier le nombre de tokens produits par an par la **durée de vie du modèle** (en *année*). Cette étape permet d'intégrer les tokens qui ne sont pas encore produits mais qui le seront au cours de l'exploitation future.

Inférence | Traitement des requêtes par le modèle - Analyse méthodologie Ecologits

Nous avons choisi **Ecologits comme socle de notre modélisation de l'empreinte liée à l'inférence**. Ce choix repose sur la robustesse de sa méthodologie, son adoption large par la communauté et son accessibilité, facilitant ainsi les futures mises à jour de la calculatrice SNCF.

Ci-dessous, les limites identifiées d'Ecologits et les enrichissements apportés dans le cadre d'Impact IA

Limites d'Ecologits

Données théoriques vs réelles

Basé sur les travaux de *ML Energy*, Ecologits modélise des scénarios optimisés sans fluctuations de demande. Il omet la consommation "de base" (idle) des GPU/serveurs, considérant l'impact de l'inférence comme purement marginal.

Périmètre fonctionnel restreint

L'outil se limite à l'inférence du GPU et du serveur. Pour couvrir l'intégralité du cycle de vie des modèles (notamment l'entraînement mais également l'embedding).

Token d'entrée

La modélisation de l'empreinte des tokens d'entrée est partielle car elle ne prends pas en compte le nombre de paramètres du modèle considéré.

Enrichissements proposés dans Impact'IA

Réseaux au cœur du centre de données et bâtiment – [voir le détail des calculs ici](#)

Intégration des composants d'infrastructures pour améliorer les estimations d'impact de la phase d'inférence afin de couvrir un périmètre le plus complet possible et prendre en compte la non-linéarité de la consommation réelle des composants

Embedding – [voir le détail des calculs ici](#)

Formule dédiée alignée sur l'esprit de la formule sur la latence d'Ecologits

Entraînement des modèles – [voir le détail des calculs ici](#)

Modélisation top-down via la consommation des centres de données. Ces informations ne sont pas encore publiques pour la plupart des fournisseurs mais seront de plus en plus accessibles grâce au Code de Conduite de la Commission Européenne sur les DC.

Token d'entrée – [voir le détail des calculs ici](#)

Formule d'Ecologits enrichie afin de considérer plus de paramètres. Ces réflexions ont été partagées avec Ecologits ; leurs futures modélisations pourra remplacer la formule actuelle si plus robuste

Inférence | Traitement des requêtes par le modèle (2/5)

Comme décrit précédemment, l'approche retenue s'appuie sur la méthodologie Ecogits (mise à jour du 19 mars 2026), enrichie pour mieux prendre en comptes les tokens d'entrée et l'environnement du GPU.

Amélioration 1 – Approximation du temps de latence en prenant en compte les tokens d'entrée et les tokens de sortie (notée $Latence_{inférence}$ - [en seconde])

Lorsqu'un utilisateur envoie une requête à un modèle de langage, le traitement se décompose en deux grandes étapes :

- Pré-remplissage (prefill) : le modèle lit et encode les tokens d'entrée afin de produire le premier token de sortie
- Décodage (decode) : le modèle génère ensuite les tokens de sortie, un par un, à un débit donné.

Le temps total d'inférence correspond donc au temps nécessaire pour effectuer ces deux étapes.

Etape 1 | Décomposition du temps d'inférence

D'après la méthodologie publiée par Ecogits, la durée totale d'inférence pour une requête est donnée par :

$$\Delta T(\#Token_{sortie}) = \min(TTFT + \#Token_{sortie} \times TPS ; \Delta T_{request})$$

Avec des valeurs standardisées par modèle :

- **TTFT** (Time To First Token) - [en milli seconde] : Temps nécessaire pour produire le premier token de sortie (phase de prefill) ;
- **TPS** (Tokens Per Second) - [en seconde] : Temps de génération des tokens de sortie (phase de decode) ;
- $\Delta T_{request}$: Mesure réelle de la latence de requête

Dans notre approche, nous excluons $\Delta T_{request}$ considéré comme non représentatif dans nos cas d'usage faisant appel à des modèles externes.

Etape 2 | Modélisation du TTFT en fonction du nombre de token d'entrée ([Agrawal et al., 2024 – Sarathi-Serve \(OSDI\)](#))

L'amélioration proposée consiste à relier explicitement le TTFT au nombre de tokens d'entrée. Des travaux expérimentaux (notamment sur Mistral-7B) montrent que le temps de prefill est approximativement linéaire avec le nombre de tokens d'entrée :

$$TTFT = Coefficient_{modèle} \times \#Token_{entrée} + 17,88$$

Le terme linéaire reflète le coût de traitement des tokens d'entrée. La constante 17,88 ms correspond à un temps incompressible, observé expérimentalement.

Le $Coefficient_{modèle}$ - [sans unité] dépend du modèle utilisé et est estimé à partir des données de latence médiane TTFT publiées par OpenRouter.

Inference duration or generation latency for the entire request ΔT

$$\Delta T(\#T_{out}) = \min\{TTFT + \#T_{out} \times TPS, \Delta T_{request}\}$$

given $\#T_{out}$


TTFT: Pre-fill latency (time-to-first-output-token)

TPS: decode latency (related to the throughput or tokens-per-second)

When possible, $\Delta T_{request}$ is measured as the max bound for ΔT

Note:

TTFT and TPS data are collected for many different providers and models thanks to [OpenRouter](#).



Temps de pré-remplissage (prefill) et de décodage pour différentes tailles d'entrée, pour Mistral-7B exécuté sur un GPU A100 unique

Inférence | Traitement des requêtes par le modèle (3/5)

Comme décrit précédemment, l'approche retenue s'appuie sur la méthodologie Ecogits (mise à jour du 19 mars 2026), enrichie pour mieux prendre en comptes les tokens d'entrée et l'environnement du GPU.

Amélioration 1 (suite) – Approximation du temps de latence intégrant les tokens d'entrée et les tokens de sortie (notée $Latence_{inférence}$ - [en seconde])

Etape 3 | Estimation du coefficient par modèle (noté $Coefficient_{modèle}$ - [sans unité])

Pour rendre la méthode généralisable à différents modèles, le coefficient est ajusté à partir d'un modèle de référence (Mistral-7B) et permet d'adapter le coefficient à d'autres modèles à partir de leur TTFT :

$$Coefficient_{modèle} = 0,062 * \frac{TTFT}{0,44}$$

Avec :

- 0,062 : coefficient mesurée pour Mistral 7B
- 0,44 : le TTFT médian de Mistral 7B (en ms)

Etape 4 | Temps de génération des tokens de sortie

Une fois le premier token généré, le modèle produit les tokens suivants à un débit moyen, noté TPS. Le temps associé à la génération des tokens de sortie est donc :

$$Temps_{decode} = \#Token_{sortie} * TPS$$


Etape 5 | Calcul de la latence d'inférence

En combinant les deux composantes précédentes, on obtient une approximation du temps total d'inférence :

$$Latence_{inférence} = \#Token_{sortie} * Latence_{token} + \frac{Coefficient_{modèle} * \#Token_{entrée} + 17,88}{1000}$$

Où la formule suivante décrite par [Ecogits v0.10](#) :

$$Latence_{token} = (Latence_{\alpha} * Paramètres_{actif|moyenne}) + (Latence_{\beta} * Batch) + Latence_{\gamma}$$



Exemple	Médian TTFT	Coefficient
ChatGPT 5.1	1,11	0.16
Mistral 7B	0,44	0,062
Sonnet 4.5	1,63	0,23
Gemini 3bc	2,83	0,40

Notre proposition consiste à utiliser les données médianes de **TTFT** de **OpenRouter** pour adapter une **corrélation linéaire** entre le nombre de input tokens et le TTFT pour Mistral 7B.

Inférence | Traitement de la requête par le modèle (4/5)

Amélioration 2 – Prise en compte des réseaux au sein des centre de données dans les résultats d'impact de l'inférence

Au sein des centre de données se trouvent des infrastructures réseau composées d'équipements tels que : les pare-feux, les routeurs et les switches.

Etape 1 | Estimation de la consommation électrique des réseaux au sein des centre de données en inférence (notée $E_{Réseau}^{inférence}$ - [en kWh])

$$E_{Réseau}^{inférence} = N_{GPU|serveur} * (P_{pare-feu} * Ratio_{pare-feu} + P_{routeur} * Ratio_{routeur} + P_{switch} * Ratio_{switch}) * \frac{Latence_{inférence}}{3600} * \frac{1}{N_{GPU|serveur} * Batch}$$

Avec :

- $N_{GPU|projet}$ - [sans unité] : Nombre de GPU utilisé pour le traitement de la requête
- $P_{pare-feu}$ - [en kW] : Puissance électrique du pare-feu (estimée à 0,095 kW)
- $Ratio_{pare-feu}$ - [sans unité] : Taux de disponibilité effective du pare-feu sur sa durée de vie (estimé à 0,0358)
- $P_{routeur}$ - [en kW] : Puissance électrique du routeur (estimée à 0,09 kW)
- $Ratio_{routeur}$ - [sans unité] : Taux de disponibilité effective du routeur sur sa durée de vie
- P_{switch} - [en kW] : Puissance électrique du switch (estimée à 0,09 kW)
- $Ratio_{switch}$ - [sans unité] : Taux de disponibilité effective du switch sur sa durée de vie (estimé à 1,468)
- $Latence_{inférence}$ - [en seconde]
- $N_{GPU|serveur}$ - [sans unité]
- $Batch$ - [sans unité]

Etape 2 | Calcul des impacts environnementaux des réseaux au sein des centre de données (notée $I_{Réseau}$ pour GWP - [en kg CO₂e] et WU - [en m³ eq])

$$I_{Réseau} = E_{Réseau}^{inférence} * FE_{FR+SW} + (I_{pare-feu}^{emb} * Ratio_{pare-feu} + I_{routeur}^{emb} * Ratio_{routeur} + I_{switch}^{emb} * Ratio_{switch}) * \frac{Latence_{inférence}}{3600} * \frac{1}{Batch * DV_{Réseau}}$$

Avec :

- $E_{Réseau}^{inférence}$ - [en kWh]
- FE_{FR+SW} - [en kg CO₂e / kWh]
- $Batch$ - [sans unité]
- $I_{réseau}^{emb}$ (GWP - [en kg CO₂e] et WU - [en m³ eq]) : Pare-feu¹ ; Routeur² ; Switch³
- $Ratio_{réseau}$ - [sans unité]
- $DV_{réseau}$ - [en heure]

¹ ResilioDB - Model hash - Fortinet FortiGate 100E : 2bc89e4b2064dba552275a82c26df6c6400edb6442592ebd8d86cbb42cb9af90

² ResilioDB - Model hash - Juniper PTX10002-36QDD : ae4208b57522c4e79278b460a4c1e4875bdb1edd594698d575c7722ee96e4ffb

³ ResilioDB - Model hash - Arista 7050TX3-48C8 : bd728dcdba0474ed95ff155182665f5bec3fda22a25a9bb0da8c560a63fb33ae

Inférence | Traitement de la requête par le modèle (5/5)

Amélioration 3 (suite) – Prise en compte des bâtiments et de l'environnement technique du centre de données dans les résultats d'impact de l'inférence

Cette partie correspond à la structure qui héberge les équipements informatiques. On y trouve notamment des équipements de refroidissement, des équipements électriques, un système d'éclairage.

Etape 1 | Calcul de la consommation électrique des bâtiments et de l'environnement technique du centre de données

Cette étape est prise compte au travers de l'intégration de la variable PUE.

Etape 2 | Estimation des impacts embarqués des bâtiments et de l'environnement technique du centre de données (noté $I_{batiment}^{GWP\ emb}$ pour GWP - [en kg CO₂e])

$$I_{batiment}^{GWP\ emb} = (E_{GPU} + E_{serveur} + E_{réseau}^{inférence}) * FE_{batiment}$$

Avec :

- E_{GPU} - [en kWh] : Consommation électrique des GPU
- $E_{serveur}$ - [en kWh] : Consommation électrique du serveur hors GPU
- $E_{Réseau}^{inférence}$ - [en kWh]
- $FE_{batiment}$ - [en kg CO₂e / kWh]

6

Annexes


Description des 16 indicateurs environnementaux d'une Analyse du Cycle de Vie

Indicateurs	Descriptif	Unité
 Potentiel de réchauffement climatique [GWP]	Potentiel de réchauffement global lié aux GES (inclus : CO ₂ ,CH ₄ ,N ₂ O,HFC, PFC...)	kgCO ₂ eq (<i>équivalent kilo carbone</i>)
 Acidification [AP]	Perte de nutriment (calcium, magnésium, potassium) et leur taux de remplacement par des éléments acides	mol H ⁺ eq (<i>équivalent Molécule d'hydrogène</i>)
 Eutrophisation marine [EPM]	Potentiel de pollution des écosystèmes marins lorsque que trop de nutriments sont introduits	kg N eq (<i>équivalent kilo d'azote</i>)
 Eutrophisation eau douce [EpF]	Potentiel de pollution des écosystèmes eau douce lorsque que trop de nutriments sont introduits, créant des algues	kg P eq (<i>équivalent kilo de phosphore</i>)
 Eutrophisation terrestre [Ept]	Potentiel de pollution des écosystèmes terrestres lorsque que trop de nutriments sont introduits	mol N eq (<i>équivalent mole d'azote</i>)
 Ecotoxicité eau douce [CTUe]	Emission des substances toxiques dans l'eau douce	CTUe (<i>équivalent comparative toxic unit</i>)
 Utilisation des sols [LU]	Impacts relatifs à l'occupation et à la transformation des terres liées à des activités humaines	-
 Appauvrissement de la couche d'ozone [ODP]	Potentiel de déplétion de la couche d'ozone dans la stratosphère	kg CFC ⁻¹¹ eq (<i>équivalent kilo de chlorofluorocarbures</i>)
 Rayonnement ionisant [IR]	Energie, libérée par certains atomes, rapportée à l'uranium	kBq U ₂₃₅ eq (<i>équivalent kilo d'uranium</i>)
 Formation photochimique d'ozone [POCP]	Potentiel de création d'une couche d'ozone photochimique au sol (smog)	kg NMVOC eq (<i>équivalent kilo de composés organiques volatils non méthaniques</i>)
 Particules fines [PM]	Concentration de solides et liquides en suspension dans un gaz pouvant engendrer des maladies	Occurrences de maladies
 Toxicité pour l'homme cancérogène [CTUh-c]	Potentiels dommages sur la santé humaine accentuant la possibilité de cancers	CTUh-c (<i>Comparative Toxic Unit for humans</i>)
 Toxicité pour l'homme non cancérogène [CTUh-nc]	Potentiels dommages sur la santé humaine	CTUh-nc (<i>Comparative Toxic Unit for humans</i>)
 Utilisation d'eau [WU]	Consommation en eau	m ³ eq (<i>équivalent mètre cube</i>)
 Utilisation des ressources fossiles [ADPf]	Quantité de l'énergie dégageable par l'extraction de ressources abiotiques fossiles	MJ (<i>mégajoule</i>)
 Utilisation des ressources minérales et métalliques [ADPe]	Quantité en équivalent antimoine retirée de la nature par l'extraction de ressources abiotiques minérales et métalliques	kg Sb eq (<i>équivalent Kilo d'antimoine</i>)

Guide pratique pour l'ajout de nouveaux modèles à Impact'IA

La bibliothèque de modèles d'Impact'IA recense actuellement 33 modèles issus de 4 fournisseurs majeurs. Pour ajouter un modèle à cette base, suivez le guide ci-dessous :

Pour afficher une feuille de calcul, cliquez avec le bouton droit sur un onglet visible, puis sélectionnez **Afficher**. Dans la boîte de dialogue **Afficher** , sélectionnez la feuille que vous souhaitez afficher, puis sélectionnez **OK**.



Pour ajouter un nouveau modèle
Sélectionnez une ligne dans le tableau, puis accédez à Accueil > Insérer > Insérer des lignes dans la feuille de calcul
Vous pouvez également cliquer avec le bouton droit sur la ligne sélectionnée, puis choisir Insérer.

Puis, renseignez les caractéristiques du modèle souhaité selon les colonnes ouvertes dans le tableau en place.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	
1	SNCF	Fournisseurs	Nom du modèle	Catégorie	Architecture	P_total (Mds)	P_total_min	P_total_max	P_active_min (Mds)	P_active_max (Mds)	Sources	Localisation	PUE	Source PUE	WUE on-site	Source WUE	P_total	P_active	Average TP	Average
7	Non	Anthropic	Claude Sonnet 4.6	Grand	MoE	440			44		https://docs.anthropic.com/en/api/claude-4.6-sonnet	USA	1,115	https://docs.anthropic.com/en/api/claude-4.6-sonnet	0,56	https://docs.anthropic.com/en/api/claude-4.6-sonnet	440	88		41
12	Oui	Google	Gemini 2.5 pro	Grand	MoE	2000			200		https://cloud.google.com/vertex-ai/docs/gemini/gemini-2.5-pro	USA	1,03	https://cloud.google.com/vertex-ai/docs/gemini/gemini-2.5-pro	0,39	https://cloud.google.com/vertex-ai/docs/gemini/gemini-2.5-pro	2000	400		91,1
14	Oui	Mistral AI	Magistral Medium	Moyen	Dense		70	120			https://docs.mistral.ai/en/latest/	SWE	1,10	https://docs.mistral.ai/en/latest/	0,03	https://docs.mistral.ai/en/latest/	95	95		48,6
31	Non	OpenAI	GPT-5.2	Grand	MoE	420			42		https://openai.com/index/gpt-5-2/	USA	1,2	https://openai.com/index/gpt-5-2/	0,563	https://openai.com/index/gpt-5-2/	420	84		42,5
35	Oui	OpenAI	text-embedding-3-large	Embedding		8					https://openai.com/index/text-embedding-3-large/				0,563	https://openai.com/index/text-embedding-3-large/	8			
36																				

Pourquoi nos résultats diffèrent de ceux publiés par le fournisseur Mistral AI ?

Lorsque nous comparons les résultats d'Impact'IA avec ceux publiés par Mistral AI, nous observons **un écart de facteur 10**, l'empreinte dite *marginale* communiquée par Mistral AI étant significativement plus élevée. Ces différences s'expliquent principalement par des différences des choix méthodologiques, des périmètres et d'hypothèses.

Notion d'impact "marginal"

- L'approche d'Ecologits (reprise dans Impact'IA) repose sur **l'approche de l'impact marginal : si aucune requête n'est exécutée alors aucun calcul n'a lieu et aucun impact n'est généré**. Autrement dit, l'impact est calculé requête par requête.
- A l'inverse, les résultats publiés par Mistral AI reposent sur une **approche bottom-up, fondée sur des données agrégées sur une longue période et intégrant la consommation continue d'un cluster de GPU**, même en l'absence de requêtes. L'impact ainsi calculé correspond davantage à un impact moyen, bien que présenté comme marginal.

Evolution du matériel dans le temps

Un autre facteur réside dans la date des données utilisées :



- Les données mobilisées par Impact'IA correspondent à des hypothèses matérielles récentes (autour de 2026 en se basant sur ML Energy)
- Les données publiées par Mistral AI datent de 2024

Entre ces deux périodes, les performances énergétiques des GPU ont progressé de manière significative, réduisant mécaniquement l'impact par unité de calcul.

Choix des données et des hypothèses

Les résultats d'ACV dépendent fortement des facteurs d'émission utilisés et des bases de données ACV mobilisées. Impact'IA et les fournisseurs d'IA ne s'appuyant pas nécessairement sur les mêmes données. Enfin, certains écarts s'expliquent par des hypothèses confidentielles. Ces éléments devraient être partagés dans de futures publications.

A ce jour, Resilio travaille toujours avec Mistral AI pour affiner l'évaluation de l'empreinte environnementale de leurs modèles à horizon 2026. Des résultats mis à jour sont annoncés pour début 2027.




Cohérence avec la norme L.1801 de L'ITU

La norme ITU-T L.1801, publiée en février 2026, est intitulée *Guidelines for Assessing the Environmental Impact of Artificial Intelligence Systems*.

Elle fournit une méthodologie pour évaluer l'empreinte environnementale des systèmes d'IA, fondée sur l'ACV telle que définie dans la recommandation ITU-T L.1410 (ou son équivalent ETSI ES 203 199). Elle cartographie les étapes du cycle de vie de l'IA (conception, développement, validation, déploiement, opération, réévaluation, retrait) sur les phases classiques de l'ACV, et exige notamment de préciser comment les impacts de l'entraînement sont répartis entre la phase de production et la phase d'usage, avec un traitement séparé de l'entraînement initial et de l'apprentissage continu.

Elle permet également de comparer un système IA à une alternative non-IA ou à d'autres systèmes IA sur une base méthodologique harmonisée.

Cette norme est destinée pour des entreprises qui développent des modèles d'IA. Le calculateur **Impact'IA** couvre partiellement les étapes de cycle de vie de la norme.



Glossaire de la section « Modélisation détaillée » (1/4)

Terme	Unité	Description	Valeur par défaut	Source de la valeur
$\#Token_{modele}$	sans unité	Nombre de tokens générés en inférence par le modèle (sur 1 an)	-	-
$Paramètres_{total}$	sans unité	Nombre total de paramètres du modèle (en inférence)	-	-
$\#Token_{ent}$	sans unité	Nombre de tokens nécessaires pour l'entraînement du modèle	-	-
$FLOPS_{ent}$	FLOPS	Nombre de FLOPS (opération de calcul par seconde) générées pour l'entraînement final	-	-
$Paramètres_{actif moyenne}$	sans unité	Nombre moyen de paramètres actifs du modèle	-	-
$Volume_{stockage}$	To	Volume de données stockées	-	-
N_{HDD}	sans unité	Nombre de disques durs nécessaires au stockage de la donnée	-	Pour un Seagate Exos 30 TB
$E_{stockage}$	kWh	Consommation électrique du stockage des données	-	-
P_{HDD}	kW	Puissance électrique du HDD	0,095 kW	Pour un Seagate Exos 30 TB
$Ratio_{HDD}$	sans unité	Taux de disponibilité effective du HDD sur sa durée de vie	20%	AI models EPOCH AI
PUE	sans unité	(Power Usage Efficiency) Indicateur d'efficacité énergétique du centre de données	Variable selon le fournisseur	Ecologits v0.10
$Durée_{ent}$	heure	Durée de l'entraînement du modèle	100 jours	AI models EPOCH AI
$\#Token_{sortie}$	sans unité	Nombre de tokens de sortie par le projet (sur 1 an)	-	-
$I_{stockage}^{GWP}$	kg CO ₂ e	Impact GWP du stockage	-	-
$I_{stockage}^{WU}$	m ³ eq	Impact WU du stockage	•	•
DV_{HDD}	heure	Durée de vie du HDD	5 ans	Hypothèse SNCF
I_{HDD}^{emb}	GWP - [kg CO ₂ e] WU - [m ³ eq]	Impacts embarqués d'un HDD	GWP : 1043 kg CO ₂ e WU : 270480 L eq	ResilioDB - model hash a6732f1d11a526d6818449833d73a613672d54918ad5112c0b4b4c077de485b6
$E_{R\&D}$	kWh	Consommation électrique de la R&D attribuable au projet étudié	-	-
$E_{ent projet}$	kWh	Consommation électrique de l'entraînement final attribuable au projet étudié	-	-
$I_{R\&D}^{GWP}$	kg CO ₂ e	Impact climatique de la R&D	-	-
FE_{monde}	kg CO ₂ e / kWh	Facteur d'émission électrique moyen mondiale	0,47301 kg CO ₂ e / kWh	Ecologits v0.10
$I_{R\&D}^{WU}$	m ³ eq	Impact de l'utilisation d'eau de la R&D	-	-
WU_{modele}	m ³ eq	Facteur d'utilisation d'eau lié au modèle	Variable selon le fournisseur	Ecologits v0.10
$Aware$	sans unité	Coefficient de disponibilité de l'eau	1,4	Aware Database
$Durée_{modele}$	jour	Nombre de jours entre le 1er janvier 2020 et la date de publication du modèle	Variable selon le modèle	Fournisseurs
$E_{ent global}$	kWh	Consommation électrique totale de l'entraînement final	-	-
$E_{par FLOPS}$	Watt	Energie consommé par FLOPS	-	-
$FLOPS_{par watt}$	FLOPS/watt	Efficacité énergétique du calcul	1,4 * 10 ¹² FLOPS/watt	Epoch AI
$E_{ent projet}$	kWh	Consommation électrique de l'entraînement finale attribuable au projet étudié	-	-
$E_{reseau}^{inférence}$	kWh	Consommation électrique des équipements réseaux en inférence	-	-
$E_{inférence}$	kWh	Consommation électrique totale de la phase d'inférence du projet	-	-
$I_{inférence}^{emb}$	GWP - [kg CO ₂ e] WU - [m ³ eq]	Impacts embarqués de la phase d'inférence du projet	-	-

Glossaire de la section « Modélisation détaillée » (2/4)

Terme	Unité	Description	Valeur par défaut	Source de la valeur
$Latence_{RAG}$	seconde	Temps de latence liée à l’embedding	-	-
$\#Token_{RAG}$	sans unité	Nombre de tokens d’entrée du RAG sur 1 an	-	-
$Batch$	sans unité	Nombre de requêtes traitée en parallèle	64	Ecologits v0.10
E_{RAG}	kWh	Consommation électrique de la phase d’embedding	-	-
$P_{serveur}$	kW	Puissance électrique du serveur (sans GPU) pour l’embedding	1,2 kW	Puissance moyenne d'un p5.48xlarge chez AWS
$N_{GPU RAG}$	sans unité	Nombre de GPU utilisés pour l’embedding	1	Hypothèse SNCF
P_{GPU}	kW	Puissance électrique du GPU	0,7 kW	Ecologits v0.10 - pour un NVIDIA H100 80GB SXM5
$P_{réseau}$	kW	Puissance électrique des équipements de réseau (pares-feux, routeurs, switches)	Variable selon l'équipement	Base empreinte & Rapport ADEME - ARCEP - ARCOM
$N_{GPU serveur}$	sans unité	Nombre de GPU par serveur	8	Un rack classique de H100 (Ecologits)
I_{RAG}^{GWP}	kg CO2e	Impact climatique de l'embedding	-	-
FE_{FR+SW}	kg CO2e / kWh	Facteur d’émission électrique moyenne France / Suède	0,0408 kg CO2e / kWh	Moyenne entre la France et la Suède - ADEME
$FE_{batiment}$	kg CO2e / kWh	Facteur d’émission électrique du bâtiment et de l’environnement technique	0,046 kg CO2e / kWh	Basé sur la donnée du RCP Cloud
$I_{réseau}^{emb.}$	GWP - [kg CO2e] WU - [m3 eq]	Impacts embarqués (hors usage) des équipements de réseau (pares-feux, routeurs, switches)	Variable selon l'équipement	ResilioDB
$Ratio_{réseau}$	sans unité	Taux de disponibilité effective des équipements réseau (pares-feux, routeurs, switches) sur leur durée de vie	Variable selon l'équipement	Base empreinte & Rapport ADEME - ARCEP - ARCOM Base empreinte
$DV_{réseau}$	heure	Durée de vie des équipements de réseau (pares-feux, routeurs, switches)	5 ans	& Rapport ADEME - ARCEP - ARCOM
$I_{serveur}^{emb.}$	GWP - [kg CO2e] WU - [m3 eq]	Impacts embarqués du serveur	GWP : (7670,30+5793,01)/2=6731,655 kg CO2e WU : (7570,63 + 1060)/2=4315,315 m3 eq	ResilioDB - pour p5.48xlarge model hash FR : 5fb423369eb5137d6a8bb200bce4f376977a4f5924f40f1b183b58a1d165359d model hash SW : 8648780a73eaf883086eb7e17185e4094623eeb21f08b7ab142ba1b58199146f
$DV_{serveur}$	heure	Durée de vie du serveur	3 ans	Valeur conservatrice - Ecologitsv0.10
$I_{GPU}^{emb.}$	GWP - [kg CO2e] WU - [m3 eq]	Impacts embarqués du GPU	GWP : 366,54 kg CO2e WU : 101,5 m3 eq	ResilioDB - pour NVIDIA H100 80GB SXM5 model hash FR : c5c38823a29224c78a48b7fd33c77b47fcfb74a4655ae68a0de9002f1fa301be
DV_{GPU}	heure	Durée de vie du GPU	3 ans	Valeur conservatrice - Ecologitsv0.10

Glossaire de la section « Modélisation détaillée » (3/4)

Terme	Unité	Description	Valeur par défaut	Source de la valeur
E_{Socle}	kWh	Consommation électrique totale du socle applicatif	-	-
$E_{Socle projet}$	kWh	Consommation électrique du socle applicatif attribuable au projet étudié	-	-
P_{noeud}	kW	Puissance électrique du nœud	0,0143 kW	ResilioDB
N_{noeud}	sans unité	Nombre de nœud	13	Basé sur les caractéristiques du Socle IA
$\#Token_{Socle}$	sans unité	Nombre de token transitant par le socle applicatif annuellement	Données mensuelles	Basé sur les données mensuelles du Socle IA)
I_{Socle}^{u+e}	GWP - [kg CO2e] WU - [m3 eq]	Impacts du socle applicatif attribuable au projet étudié	-	-
DV_{noeud}	heure	Durée de vie des nœuds du socle	4 ans	Hypothèse SNCF
I_{noeud}^{emb}	GWP - [kg CO2e] WU - [m3 eq]	Impacts embarqués du nœud	GWP : (42,13+30,85)/2=36,49 kg CO2e WU : (43,57 + 61,58)/2=52,575 m3 eq	ResilioDB - pour 16Go, 4vCpu model hash FR : 9f4a71bae40b335f13d522e949ace0b8acfc641c987212a4198dc238d3949c0f Model hash SW : 2b9ab01b17cf98daa8683976b0735227d96b5b86450e6742544099ada642e046
$Compute_{modele}$	kW	Puissance de calcul globale des fournisseurs pour leurs infrastructures IA	Variable selon le fournisseur	Fournisseurs
$Ratio_{inference}$	sans unité	Proportion de la puissance installée dédiée l'inférence de modèle	20%	Hypothèse SNCF
$\#Modele_{actif}$	sans unité	Nombre de modèles actifs (ayant une durée de vie de 2 ans à partir de la date de publication du modèle)	Variable selon le fournisseur	Fournisseurs
$FLOPs_{modele}$	FLOPS	Nombre de FLOPS nécessaire (volume d'opération de calcul par seconde)	-	-
$Compute_{modele}$	kW	Puissance de calcul globale par modèle	-	-
ϵ_{total}	sans unité	Facteur pour tenir compte des conditions réelles d'utilisation de l'infrastructure	0,15	$\epsilon_{total} = 0,5 * 0,5 * \frac{1}{1,2} * 0,7$
$TTFT$	milliseconde	(Time To First Token) : Temps nécessaire pour produire le premier token de sortie (phase de prefill)	Variable selon le modèle	Open Routeur
TPS	seconde	(Tokens Per Second) : Temps de génération des tokens de sortie (phase de decode)	Variable selon le modèle	Open Routeur
$\Delta Trequest$	seconde	Mesure réelle de la latence de requête	Non applicable	Non applicable
$Coefficient_{modele}$	sans unité	Dépend du modèle utilisé et est estimé à partir des données de latence médiane TTFT publiées par OpenRouter	Variable selon le modèle	Basé sur les travaux réalisés sur Mistral 7B
$\#Token_{entrée}$	sans unité	Nombre de tokens d'entrée par le projet (sur 1 an)	•	-
$Temps_{decode}$	Seconde	Temps de génération des tokens de sortie	•	-
$Latence_{inférence}$	Seconde	Temps de latence d'inférence	•	-
$Latence_{token}$	Seconde	Temps de latence par token	•	Ecologits v0.10

Glossaire de la section « Modélisation détaillée » (4/4)

Terme	Unité	Description	Valeur par défaut	Source de la valeur
$P_{pare-feu}$	kW	Puissance électrique du pare-feu	0,095 kW	Base empreinte & Rapport ADEME - ARCEP - ARCOM
$Ratio_{pare-feu}$	Sans unité	Taux de disponibilité effective du pare-feu sur sa durée de vie	0,0358	
$P_{routeur}$	kW	Puissance électrique du routeur	0,09 kW	
$Ratio_{routeur}$	Sans unité	Taux de disponibilité effective du routeur sur sa durée de vie	0,286	
P_{switch}	kW	Puissance électrique du switch	0,09 kW	
$Ratio_{switch}$	Sans unité	Taux de disponibilité effective du switch sur sa durée de vie	1,468	
$I_{pare-feu}^{u+e}$	GWP - [kg CO2e] WU - [m3 eq]	Impacts à l'usage et embarqués du pare-feu	GWP : (1073,22+692,74)/2=882,98 kg CO2e	ResilioDB - pour Fortinet FortiGate 100E Firewall model hash FR : 2bc89e4b2064dba552275a82c26df6c6400edb6442592ebd8d86cbb42cb9af90
			WU : (1315,55 + 1922,65)/2=1619,1 m3 eq	model hash SW : 73b033e7339bdac0e794f832b6c757667dc2efe168b584e7f8f94c5cd59364ec
$I_{routeur}^{u+e}$	GWP - [kg CO2e] WU - [m3 eq]	Impacts à l'usage et embarqué du routeur	GWP : (2439,72 + 1391,81)/2=1915,765 kg CO2e	ResilioDB - pour Juniper PTX10002-36QDD Model hash FR : ae4208b57522c4e79278b460a4c1e4875bdb1edd594698d575c7722ee96e4ffb
			WU : (3484,72+5156,81)/2=4320,765 m3 eq	Model hash SW : 18a7aea4eff18826966df43cdca24688ed62043b058ab675f1ab26751cbfdf83
I_{switch}^{u+e}	GWP - [kg CO2e] WU - [m3 eq]	Impacts à l'usage et embarqué du switch	GWP : (1633,60+980,08)/2=1306,84 kg CO2e	ResilioDB - pour Arista 7050TX3-48C8 Model hash FR : bd728dcdba0474ed95ff155182665f5bec3fda22a25a9bb0da8c560a63fb33ae
			WU : (2203,41+ 3246,18)/2 = 2724,795 m3 eq	Model hash SW : c68762e8aaef1416c05ddc0bb87b3c89541e1d2aba7bf76fa58cb5974c929bc7
$E_{Réseau}^{inférence}$	kWh	Consommation électrique des réseaux au sein du centre de donnée	-	-
$I_{batiment}^{GWP emb}$	kg CO2e	Impacts climatiques embarqués des bâtiments et de l'environnement technique du centre de données	-	-
E_{GPU}	kWh	Consommation électrique des GPU	-	-
$E_{serveur}$	kWh	Consommation électrique du serveur (hors GPU)	-	-