Impact’IA vs Ecologits –

Comparaison des périmètres modélisés

AGENDA

1

Impact’IA

2

Impact’IA vs Ecologits

1

Impact’IA :

validation de la modélisation

Résultats moyens Impact’IA – Introduction

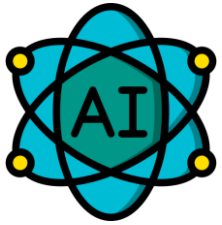
Les calculs ont été fait :



En considérant 76 millions de tokens d’entrée et 76 millions de tokens de sortie



Avec une hypothèse de 1000 requêtes par mois



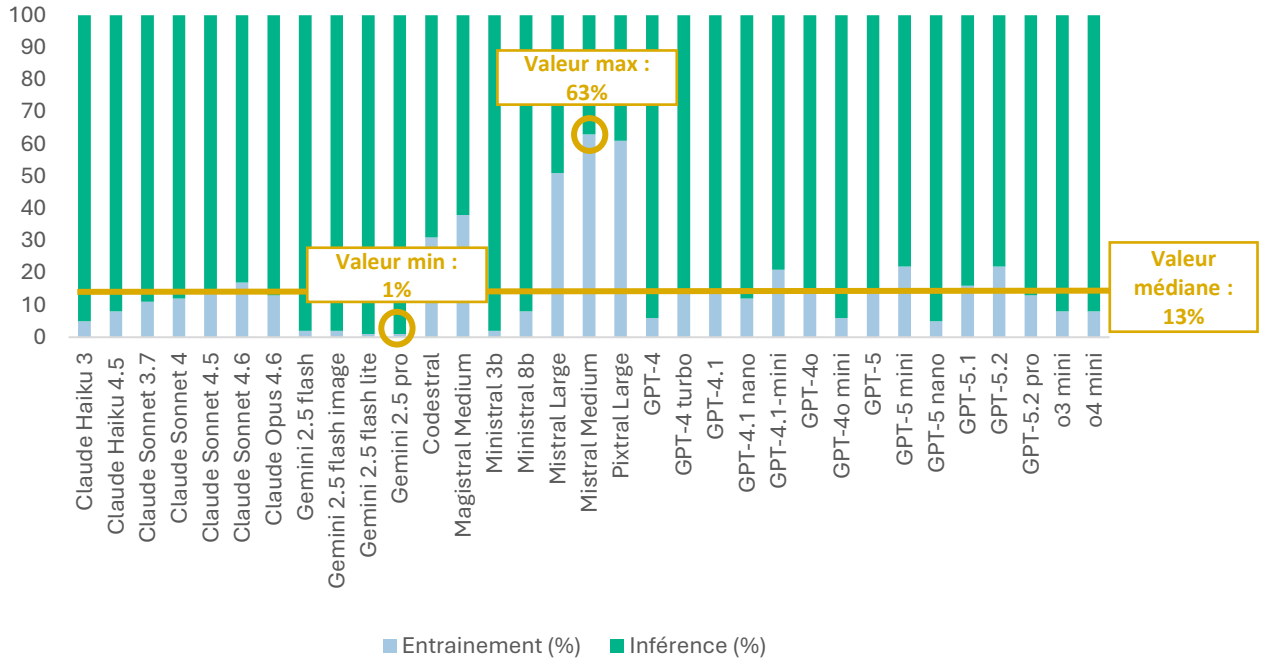
Pour les 33 modèles présents dans la calculatrice Impact’IA

Résultats moyens Impact'IA – Part d'inférence et cycle de vie

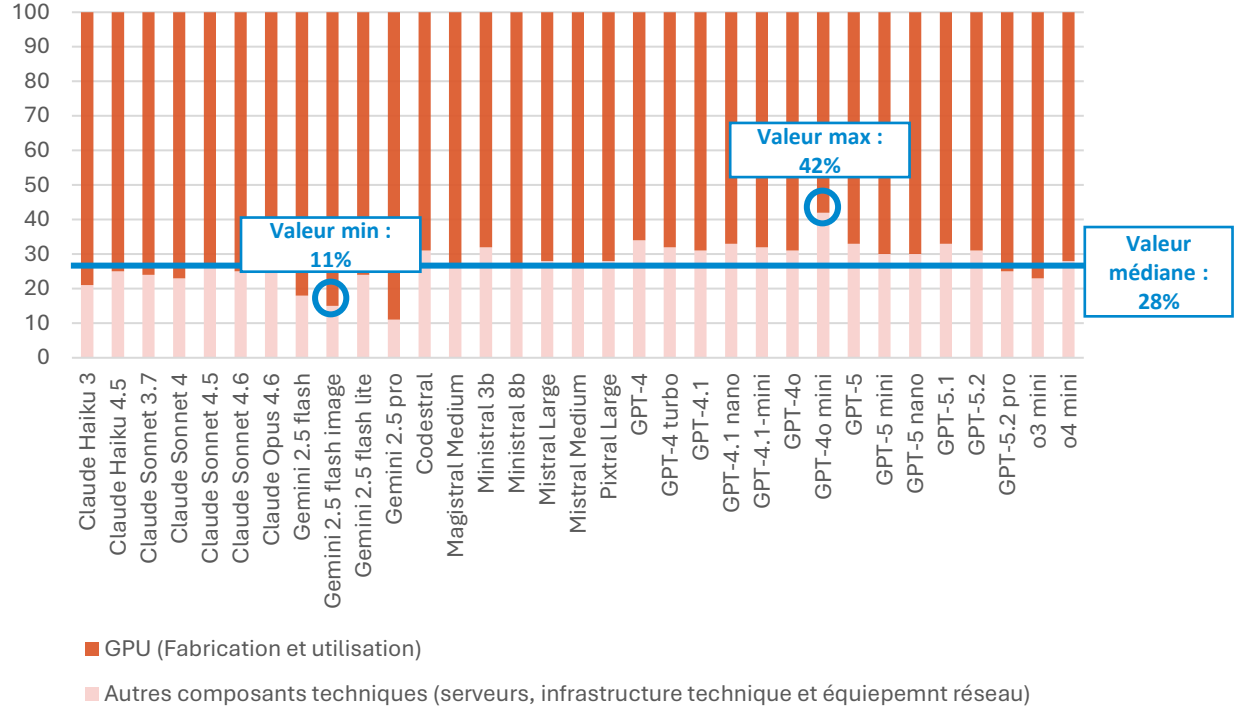
Rappels

- *Inférence = Utilisation du modèle après son entraînement (chaque requête, chaque réponse générée)*
- *Entrainement = création du modèle IA*
- *Serveurs = CPU, RAM, stockage, chassis, radiateur, alimentation*
- *Équipements réseaux = pare-feu, switchs, routeurs)*
- *Infrastructures techniques = équipements électriques, équipements de refroidissement, éclairage)*

Répartition par modèle des parts d'inférence et d'entraînement dans l'impact carbone (en %)



Zoom sur l'inférence -Répartition par modèle des parts du GPU vs autre infrastructure technique dans l'empreinte carbone de l'inférence (en %)



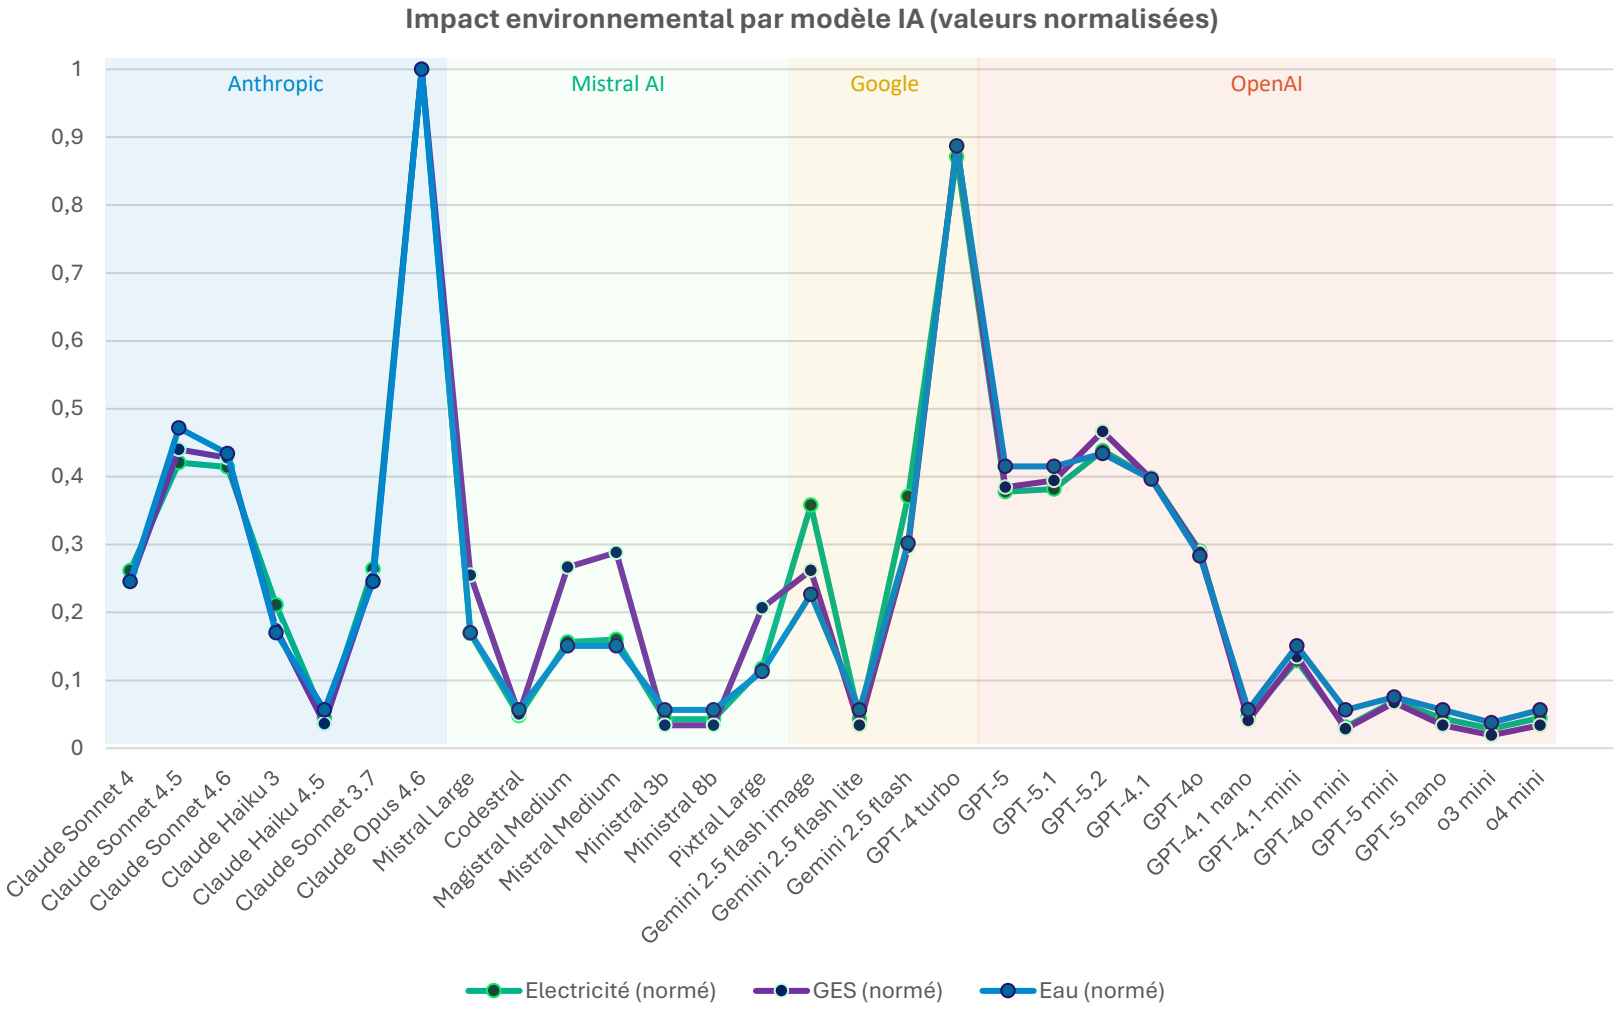
Conclusions

- **La part de l'entraînement** dans l'empreinte environnementale d'un modèle IA est **a pour médiane 13% et atteint une valeur maximale de 63%**. L'entraînement d'un modèle n'est donc **pas négligeable** et est très conséquent unitairement, **dépassant la part de l'inférence pour certains modèles**. Il ne devient marginal que dans le cas des grands modèles frontières.
- **Les infrastructures techniques** utilisées pendant la phase d'inférence d'un modèle IA, hors GPU, représentent **en moyenne 1/3 de l'empreinte de l'inférence**, avec une part **pouvant atteindre 42%** de l'empreinte carbone. Elles ne sont donc **pas négligeables dans la modélisation de la calculatrice Impact'IA**

Résultats moyens Impact'IA – Evolution des 3 impacts environnementaux

Périmètre de comparaison

- Les valeurs sont normées, la référence prise est le modèle Claude Opus 4.6
- Nous avons exclu Gemini 2.5 pro, GPT-4 et GPT 2.5 pro de l'étude, leur impact étant trop élevé



Conclusions

Les trois impacts environnementaux, carbone, eau et électricité, sont fortement corrélés. Ils évoluent globalement de la même manière. Piloter la consommation électrique revient à piloter l'ensemble de l'empreinte environnementale. En effet, la modélisation d'Impact'IA a été faite de manière à déduire l'utilisation (voir si c le bon mot) d'eau et le potentiel réchauffement climatique (GES) de l'électricité consommée.

2

Impact’IA vs Ecologits :

comparaison des résultats et périmètres

Impact'IA vs Ecologits – Données et périmètre

Périmètre de la comparaison

- La simulation est faite avec :
  - Impact'IA : 608 millions de tokens d'entrée et 152,5 millions de tokens de sortie pour Impact'IA (en moyenne, une requête consommant 152M de tokens de sortie en consomme 608M en entrée)
  - Ecologits : 152 millions de tokens de sortie pour Ecologits (la méthodologie Ecologits ne prend en compte que le nombre de tokens de sortie)
- La comparaison est faite sur les 24 modèles communs aux deux calculatrices

Phase	Élément pris en compte	Impact'IA	Ecologits
Pré-entraînement	• **Génération & Stockage des données d'entraînement** • **Expérimentations et entraînements test (R&D)**	✓	✗
Entraînement	• **Infrastructure d'entraînement du modèle final via les FLOP** • **Autres composants techniques du serveur (ex : CPU, RAM, stockage, équipement réseau, châssis)** • **Bâtiment et infrastructures des datacenters d'entrainement**	✓	✗
Pré-inférence	**Embedding de la base documentaire (RAG)**	✓	✗
Périmètre comparé **Inférence**	**Composants techniques du serveur hors GPU (ex: CPU, RAM, stockage, équipement réseau, châssis)**	✓	✗
	Infrastructure de calcul (GPU)	✓	✓
	Bâtiment et infrastructures du datacenter	✓	✗
	Embedding des requêtes utilisateur	✓	✗
	Socle applicatif	✓	✗
	Tokens d'entrée	✓	Uniquement le temps de traitement du premier token
	Tokens de sortie	✓	✓

Autres éléments différenciants	Impact'IA	Ecologits
Facteurs d'impact	ResilioDB	Données Open Source (Our World in Data, ADEME Base Empreinte, World Resource Institute data)
Périmètre de l'approche ACV (Analyse de cycle de vie)	**ACV simplifiée** en intégrant les émissions embarquées notamment liées à la fabrication	**Concentrée sur la phase d'utilisation**, sans prendre en compte les autres étapes.

Lexique

- *Inférence = Utilisation du modèle après son entraînement (chaque requête, chaque réponse générée)*
- *Entrainement = création du modèle IA*
- *Équipement réseau = pare-feu, switchs, routeurs, au sein du Datacenter*
- *Infrastructures techniques = équipements électriques, équipements de refroidissement, éclairage)*
- *Socle applicatif : Outils de support assurant le stockage des conversations, l'hébergement de la base documentaire sur des serveurs internes à la SNCF*
- *Embedding : Traduction des documents en suite de nombre (vecteur) permettant la comparaison des contenus*
- *Tokens : Le token est l'unité élémentaire de traitement pour un modèle IA*
- *Tokens d'entrée : tokens utilizes pour le traitement d'une requête IA*
- *Tokens de sortie : tokens utilizes pour la génération d'une réponse par un modèle IA*
- *Facteurs d'impact : coefficient quantitatif qui permet de relier une donnée d'activité à son équivalent en impact environnemental*
- *FLOP (Floating Point Operation) : opération mathématique élémentaire effectuée par un modèle d'IA pour produire une réponse.*

Impact'IA vs Ecologits – Comparaison des résultats pour l'inférence

Fournisseur	Modèle	Ratio Électricité (Impact IA/Ecologits)	Ratio Carbone (Impact IA/Ecologits)	Ratio Eau (Impact IA/Ecologits)
Claude	Claude Haiku 4.5	3,0	2,7	41,8
	Claude Sonnet 4.5	1,5	1,5	19,6
	Claude Sonnet 4.6	1,6	1,6	18,4
	Claude Opus 4.6	1,5	1,7	16,9
Google	Gemini 2.5 flash	1,6	1,7	14,0
	Gemini 2.5 flash image	1,6	2,1	12,6
	Gemini 2.5 flash lite	5,1	5,1	74,0
	Gemini 2.5 pro	1,4	1,7	5,0
Anthropic AI	Codestral	4,5	4,0	68,3
	Magistral Medium	1,8	1,6	18,6
	Ministral 3b	4,4	2,8	65,2
	Ministral 8b	4,4	3,0	65,1
	Mistral Large	1,8	1,9	20,4
	Mistral Medium	1,8	1,7	19,4
Open AI	GPT-4.1	1,5	1,6	17,6
	GPT-4.1 nano	2,3	1,5	36,3
	GPT-4.1-mini	2,3	2,3	28,4
	GPT-5	1,7	2,0	23,5
	GPT-5 mini	2,0	2,2	26,5
	GPT-5 nano	4,9	4,9	71,3
	GPT-5.1	1,7	1,9	20,0
	GPT-5.2	1,6	1,7	17,5
	GPT-5.2 pro	1,4	1,4	9,9
	o4 mini	4,7	4,6	66,1
Moyenne		2,5	2,4	32,3
Commentaires		En moyenne, **Impact'IA > Ecologits.** Cela est dû à la différence de périmètre entre les deux calculatrices. En effet, Impact'IA prend en considération les tokens d'entrée et l'embedding des requêtes ainsi que le socle applicatif, qui représente une part non négligeable de l'inférence. De plus, l'ajout du bâtiment, des infrastructures techniques et des composants techniques du serveur hors GPU engendre une consommation électrique de l'inférence d'un modèle IA plus importante.	En moyenne, **Impact'IA > Ecologits**. Cela s'explique par la couverture d'un périmètre plus large incluant le bâtiment et les composants techniques du serveur hors GPU. De plus, les facteurs d'émission sont différents pour les deux calculatrices. Impact'IA se base sur les facteurs d'émission disponibles sur Resilio DB, ce n'est pas le cas d'Ecologits. Enfin, la modélisation d'Impact'IA considère l'embedding des requêtes, qui fait croître l'emission de GES.	En moyenne, **Impact'IA >> Ecologits**. Cela peut s'expliquer par 3 facteurs : • Une compariaosn est faite entre de l'eau et de l'eau équivalente, qui englobe toute l'eau nécessaire tout au long du cycle de vie d'un modèle IA • L'ajout de la consommation d'eau de la phase d'utilisation (en plus de la phase embarquée/fabrication) • Utilisation de la méthodologie aware, qui calcule l'empreinte de l'eau en pondérant les volumes d'eau consommés par un coefficient de rareté locale.

Impact’IA vs Ecologits – Synthèse des principales différences



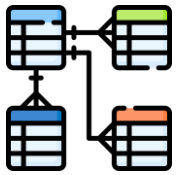
Impact’IA couvre un périmètre bien plus important en termes de composants techniques :

- *Composants techniques du serveur hors GPU (ex: CPU, RAM, stockage, équipement réseau, châssis)*
- *Bâtiment et infrastructures du datacenter*
- *Socle applicatif*



Impact’IA couvre un périmètre bien plus important en termes de cycle de vie :

- *Phase embarquée (fabrication) + phase d’utilisation*



Impact’IA se base sur une modélisation améliorée :

- *Modélisation de l’embedding des requêtes (traduction des requêtes en langage vectoriel, facilitant leur comparaison à d’autres contenus)*
- *Modélisation des tokens d’entrée*



Impact’IA se base sur les facteurs d’émission de Resilio DB

Merci

Direction Numérique groupe SNCF

jeudi 10 septembre 2026